

1
2
3
4
5
6
7
8
9
10
11
12
13
14

{



}



Machine Learning avec 'Scikit-Learn'

< Formateur : Onesime **MBULAYI** >

Résumé 'la formation se déroulera en 9 séances'

{

Sommaire () Installation et préparation de l'environnement du travail **Python** et **ANACONDA**.

Séance 1() Introduction en Machine Learning

Séance 2() Prétraitement et exploration des données

Séance 3() Apprentissage supervisé : Regression

}

Résumé 'la formation se déroulera en 9 séances'

{

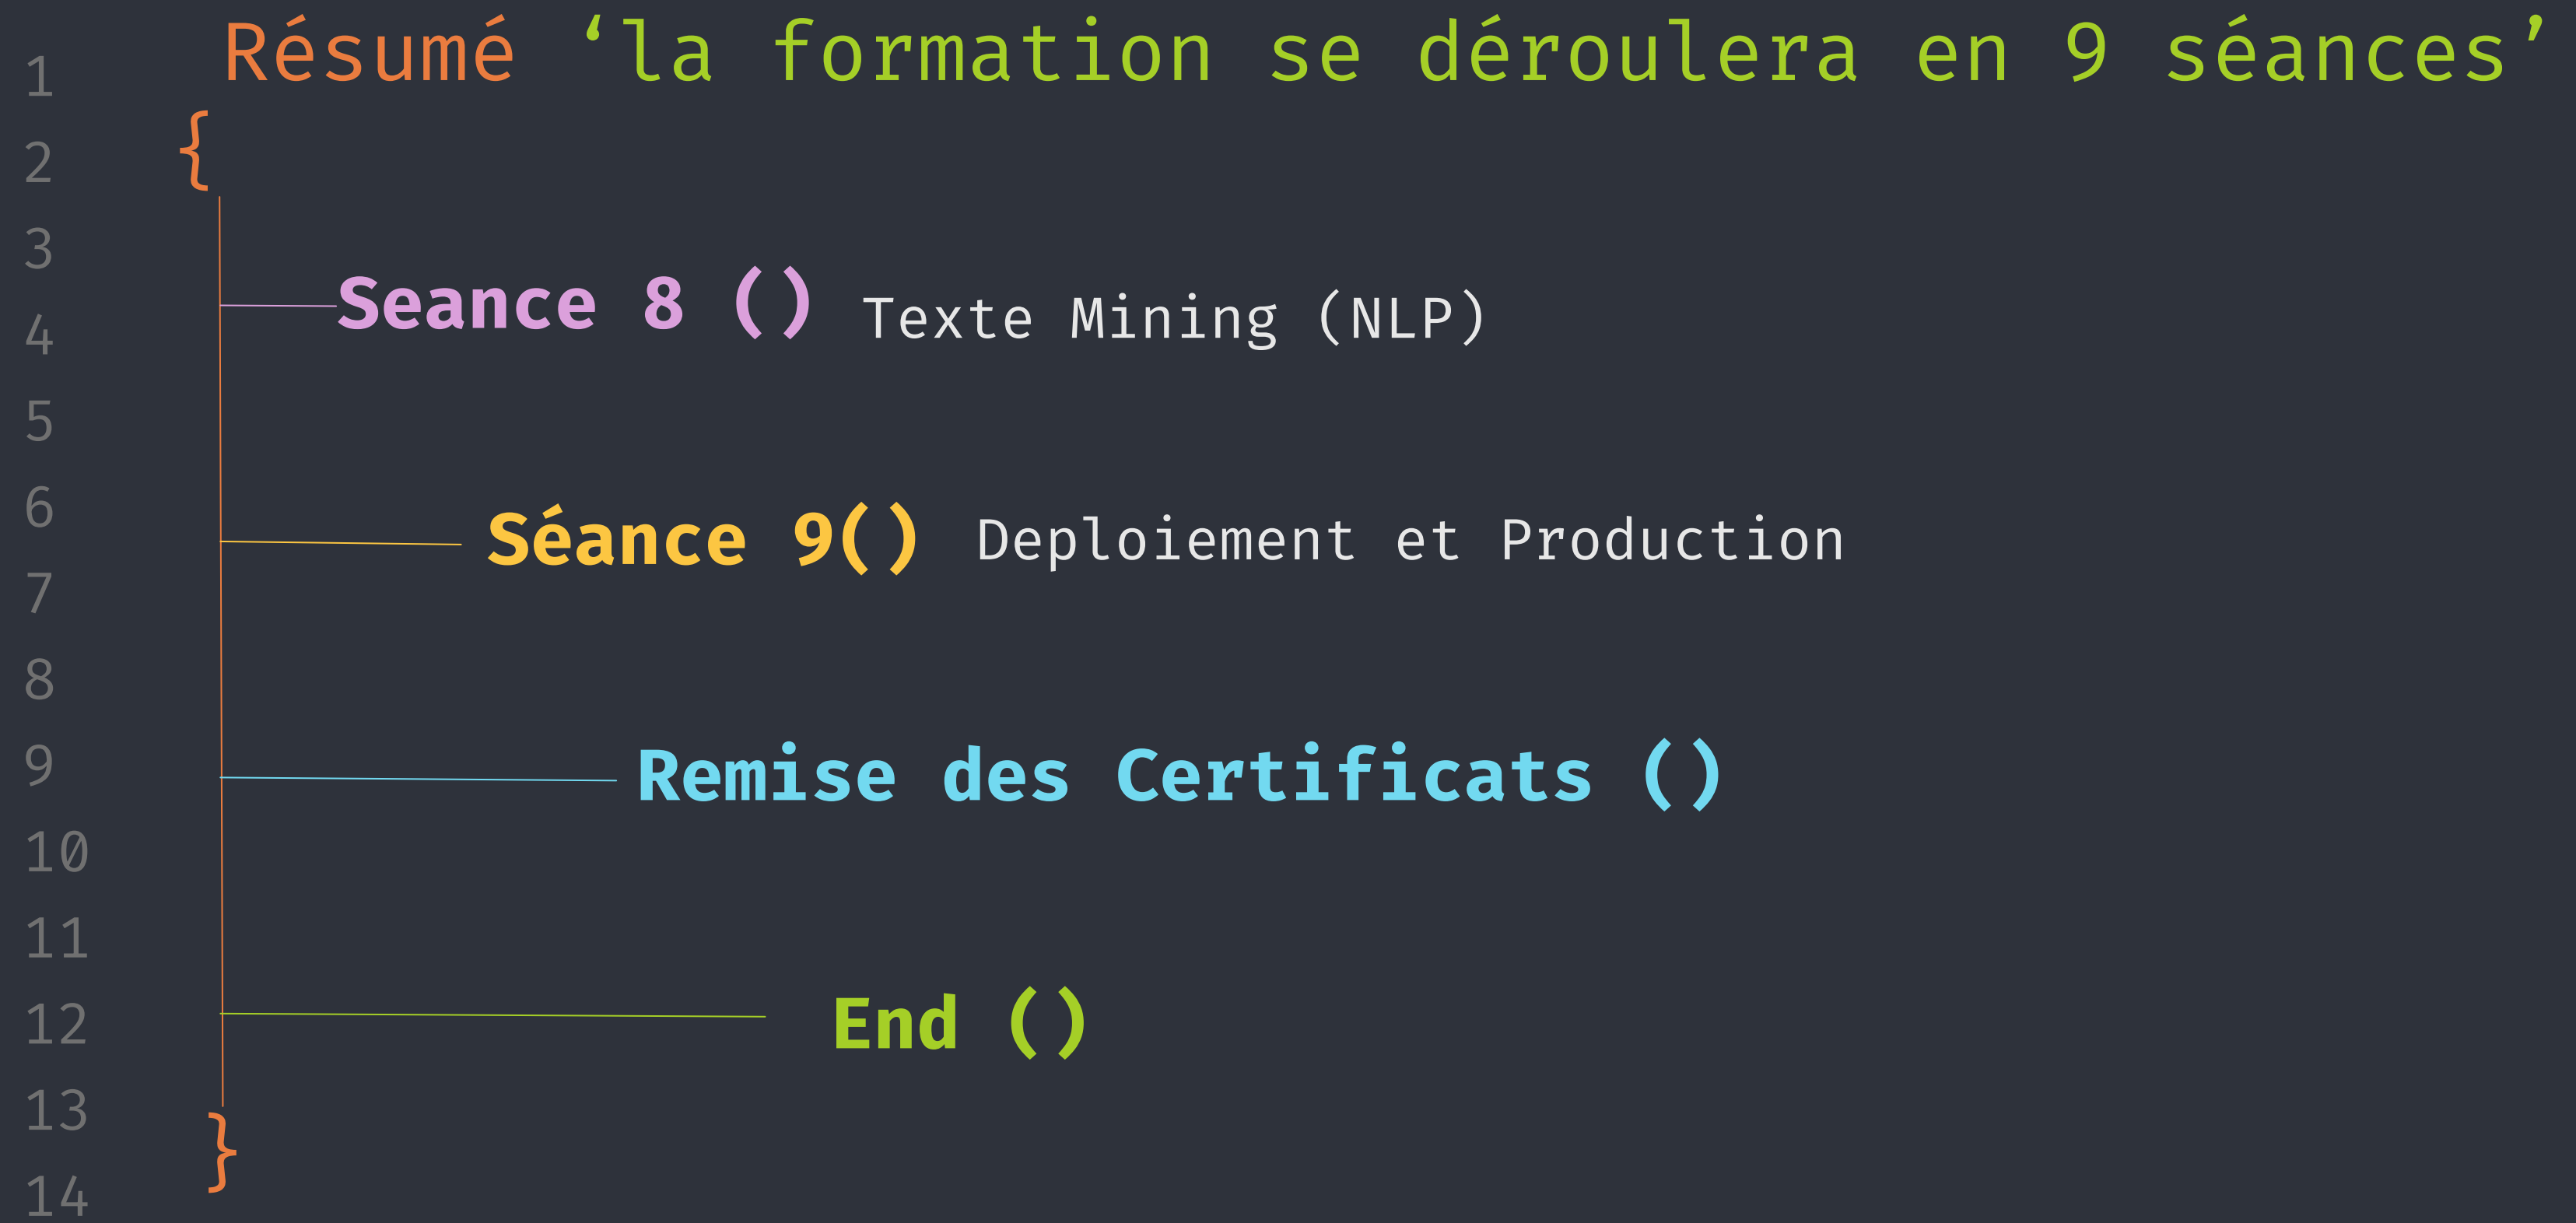
Séance 4 () Apprentissage supervisé : Classification

Séance 5() Apprentissage non Supervisé : Clustering

Séance 6() Evaluation et selection des modèles

Séance 7() Réduction de la dimensionnalité

}




{ Séance 1()

'Présentation de Machine Learning'


}

L'apprentissage automatique est un sous-domaine de **l'intelligence artificielle** consacré à la compréhension et à la création de méthodes permettant d'imiter la façon dont les humains apprennent. Ces méthodes incluent l'utilisation d'algorithmes et de données pour améliorer les performances sur un ensemble de tâches.



'C'est quoi Scikit-Learn ?'


Scikit-learn, également connu sous le nom de `sklearn`, est une bibliothèque d'apprentissage automatique Python open source et robuste. Elle a été créée pour simplifier le processus de mise en œuvre de l'apprentissage automatique et des modèles statistiques en Python.



La bibliothèque permet aux praticiens de mettre en œuvre rapidement une vaste gamme d'algorithmes d'apprentissage automatique supervisés et non supervisés via une interface cohérente.

Sklearn a été construit sur **SciPy** et fonctionne sur tous les types de données numériques stockées sous forme de tableaux NumPy, de matrices creuses SciPy et de tous les autres types de données pouvant être convertis en tableaux numériques tels que **Pandas DataFrames**.

'Ecosysteme de Scikit-Learn ?'



'Data?'



Le premier aspect de sklearn que nous allons explorer concerne les données ; Scikit-learn est livré avec des ensembles de données d'apprentissage automatique standard, ce qui signifie que vous n'êtes pas obligé de les télécharger à partir d'un site Web ou d'une base de données externe.


Parmi les exemples de **jeux de données(DATASET)** disponibles dans sklearn, on trouve `Boston`, `iris`, `diabetes`, `digits`, `linnerud`, `wine`, `breast_cancer`, `sample_images`. Par exemple, le data d'iris peut être utiliser pour la classification et le dataset diabète pour la régression.

Pour notre exemple, nous utiliserons **le jeu de données sur le iris.**

Environnement 'Installation Python';

Étape 1 : Téléchargement du programme d'installation Python


1. Accéder à l'officiel **Python download page for Windows**.
2. Trouvez une version stable de Python
3. Cliquez sur le lien approprié à votre système pour télécharger le fichier exécutable : programme d'installation Windows (64 bits) ou programme d'installation Windows (32 bits).



Environnement 'Installation Python';


Étape 2: Exécution du programme d'installation

1. Une fois le programme d'installation téléchargé, double-cliquez sur le fichier .exe, par exemple **python-3.10.10-amd64.exe**, pour exécuter le programme d'installation Python.
2. Cochez la case Installer le lanceur pour tous les utilisateurs, qui permet à tous les utilisateurs de l'ordinateur d'accéder à l'application de lancement Python.
3. Cochez la case Ajouter python.exe au PATH, qui permet aux utilisateurs de lancer Python à partir de la ligne de commande.



Environnement 'Installation Python';

1. Si vous débutez avec Python et que vous souhaitez l'installer avec les fonctionnalités par défaut décrites dans la boîte de dialogue, cliquez sur Installer maintenant et passez à l'étape 4. Pour installer d'autres fonctionnalités facultatives et avancées, cliquez sur Personnaliser l'installation et continuez.
2. Les fonctionnalités facultatives incluent des outils et des ressources communs à Python et vous pouvez les installer tous, même si vous ne prévoyez pas de les utiliser.



Environnement 'Installation Python';


Sélectionnez les options qui correspondent à vos besoins :

- **Installer pour tous les utilisateurs** : recommandé si vous n'êtes pas le seul utilisateur sur cet ordinateur
- **Associer les fichiers à Python** : recommandé, car cette option associe tous les types de fichiers Python au lanceur ou à l'éditeur
- **Créer des raccourcis pour les applications installées** : recommandé pour activer les raccourcis pour les applications Python
- **Ajouter Python aux variables d'environnement** : recommandé pour activer le lancement de Python
- **Précompiler la bibliothèque standard** : non requis, cela pourrait ralentir l'installation
- **Télécharger les symboles de débogage et télécharger les binaires de débogage** : recommandé uniquement si vous prévoyez de créer des extensions C ou C++

Notez le répertoire d'installation de Python au cas où vous auriez besoin de vous y référer ultérieurement.

Environnement 'Installation Python';

1. Cliquez sur **Installer** pour démarrer l'installation.
2. Une fois l'installation terminée, un **message indiquant que l'installation a réussi s'affiche**.



Environnement 'Installation Python';

Étape 3 Ajout de Python aux variables d'environnement (facultatif)

Ignorez cette étape si vous avez sélectionné Ajouter Python aux variables d'environnement lors de l'installation.

Si vous souhaitez accéder à Python via la ligne de commande mais que vous n'avez pas ajouté Python à vos variables d'environnement lors de l'installation, vous pouvez toujours le faire manuellement.

Avant de commencer, recherchez le répertoire d'installation de Python sur votre système. Les répertoires suivants sont des exemples de chemins de répertoire par défaut :

- **C:\Program Files\Python310** : si vous avez sélectionné Installer pour tous les utilisateurs lors de l'installation, le répertoire sera alors à l'échelle du système
- **C:\Users\Onesime\AppData\Local\Programs\Python\Python310** : si vous n'avez pas sélectionné Installer pour tous les utilisateurs lors de l'installation, le répertoire sera alors dans le chemin d'accès de l'utilisateur Windows.

Notez que le nom du dossier sera différent si vous avez installé une version différente, mais démarrera toujours avec Python.

1. Allez dans **Démarrer** et saisissez les **paramètres système avancés** dans la barre de recherche.
2. Cliquez sur **Afficher les paramètres système avancés**.
3. Dans **la boîte de dialogue Propriétés système**, cliquez sur **l'onglet Avancé**, puis sur **Variables d'environnement**.

Environnement 'Installation Python';

1. En fonction de votre installation :

- Si vous avez sélectionné **Installer pour tous les utilisateurs** lors de l'installation, sélectionnez **Chemin** dans la liste des **variables système** et cliquez sur **Modifier**.
- Si vous n'avez pas sélectionné **Installer pour tous les utilisateurs** lors de l'installation, sélectionnez **Chemin** dans la liste des variables utilisateur et cliquez sur **Modifier**.
- Cliquez sur **Nouveau** et entrez le chemin du répertoire Python, puis cliquez sur **OK** jusqu'à ce que toutes les boîtes de dialogue soient fermées.

Étape 4 Vérifier l'installation de Python

- Vous pouvez vérifier si l'installation de Python a réussi soit via la ligne de commande, soit via l'application Environnement de développement intégré (IDLE), si vous avez choisi de l'installer.
- Allez dans **Démarrer** et saisissez cmd dans la barre de recherche. Cliquez sur **Invite de commandes**.
- Saisissez la commande suivante dans l'invite de commandes :

```
python --version
```

Output

```
Python 3.10.10
```


Environnement 'Installation d'anaconda';

Anaconda est un gestionnaire de paquets, un gestionnaire d'environnement et une distribution Python qui contient une collection de paquets open source. C'est un avantage car lorsque vous travaillez sur un projet de Data Science, vous constaterez que vous avez besoin de nombreux paquets différents (numpy, scikit-learn, scipy, pandas pour n'en citer que quelques-uns), avec lesquels une installation d'Anaconda est préinstallée.


Si vous avez besoin de paquets supplémentaires après l'installation d'Anaconda, vous pouvez utiliser le gestionnaire de paquets d'Anaconda, **conda** ou **pip** pour installer ces paquets. C'est très avantageux car vous n'avez pas à gérer vous-même les dépendances entre plusieurs paquets. Conda facilite même le basculement entre Python 2 et 3. En fait, l'installation d'Anaconda est également la méthode recommandée pour installer **Jupyter Notebooks**.

Comment télécharger et installer Anaconda

1. Accédez au site Web d'Anaconda et choisissez un programme d'installation graphique Python 3.x (A) ou un programme d'installation graphique Python 2.x (B).




2. Localisez votre téléchargement et double-cliquez dessus.




Environnement 'Installation d'anaconda';

Lorsque l'écran ci-dessous apparaît, cliquez sur Suivant.




Environnement 'Installation d'anaconda';


3. Lisez le contrat de licence et cliquez sur J'accepte.



4. Cliquez sur Suivant.




5. Notez votre emplacement d'installation, puis cliquez sur Suivant.




6. Il s'agit d'une partie importante du processus d'installation. L'approche recommandée consiste à ne pas cocher la case pour ajouter Anaconda à votre chemin. Cela signifie que vous devrez utiliser Anaconda Navigator ou l'invite de commande Anaconda (située dans le menu Démarrer sous « Anaconda »). lorsque vous souhaitez utiliser Anaconda (vous pouvez toujours ajouter Anaconda à votre PATH plus tard si vous ne cochez pas la case).


Si vous souhaitez pouvoir utiliser Anaconda dans votre invite de commande (ou git bash, cmd, powershell, etc.), veuillez utiliser l'approche alternative et cocher la case.




7. Cliquez sur Suivant.



8. Vous pouvez installer Microsoft VSCode si vous le souhaitez, mais cela est facultatif.




9. Cliquez sur Terminer.



Comment ajouter Anaconda au chemin (facultatif)

Il s'agit d'une étape facultative. Elle concerne le cas où vous n'avez pas coché la case à l'étape 6 et souhaitez maintenant ajouter Anaconda à votre chemin. L'avantage de cette opération est que vous pourrez utiliser Anaconda dans votre invite de commande, Git Bash, cmdr, etc.

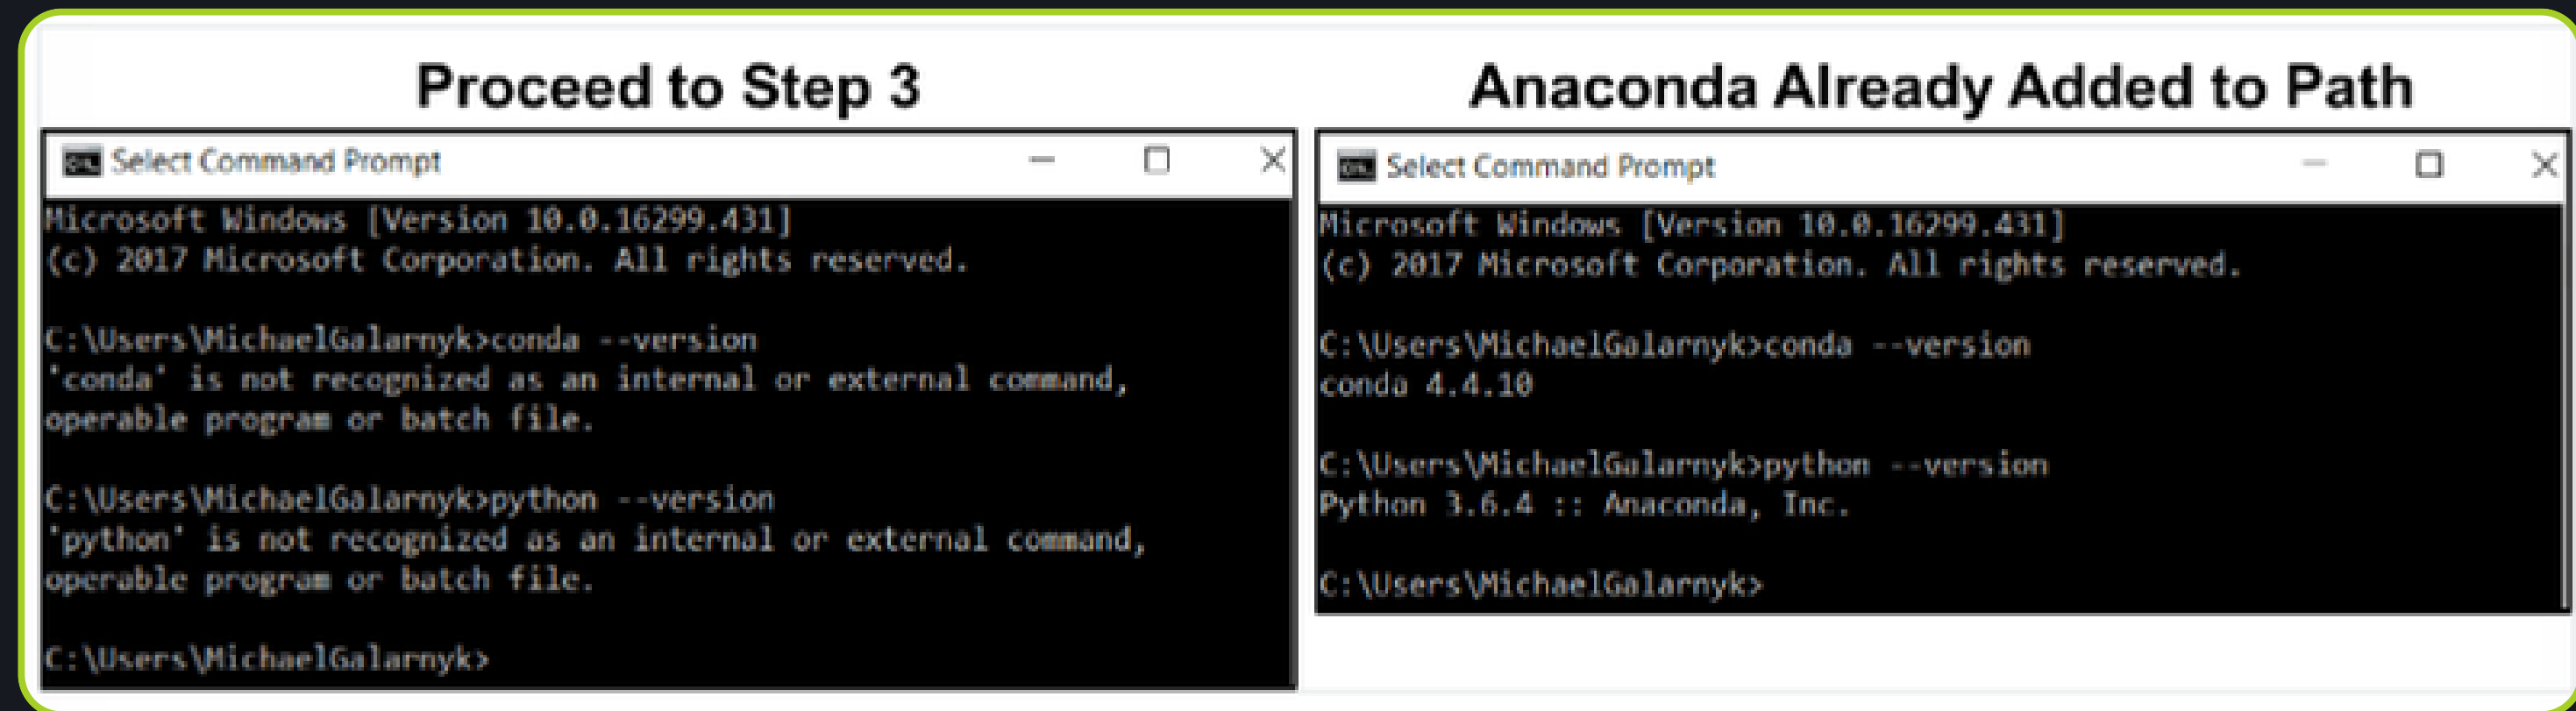
1. Ouvrez une invite de commande.



2. Vérifiez si Anaconda est déjà ajouté à votre chemin. Entrez les commandes ci-dessous dans votre invite de commande. Cela permet de vérifier si Anaconda est déjà ajouté à votre chemin. Si vous obtenez une erreur de commande non reconnue comme dans le côté gauche de l'image ci-dessous, passez à l'étape 3. Si vous obtenez un résultat similaire au côté droit de l'image ci-dessous, vous avez déjà ajouté Anaconda à votre chemin.

`conda --version`


`python --version`



3. Si vous ne savez pas où se trouvent votre conda et/ou python, ouvrez une invite Anaconda et saisissez les commandes suivantes. Cela vous indique où se trouvent conda et python sur votre ordinateur.

`where conda`

`where python`



```
Anaconda Prompt


(base) C:\Users\MichaelGalarnyk>where conda
C:\Users\MichaelGalarnyk\Anaconda3\Library\bin\conda.bat
C:\Users\MichaelGalarnyk\Anaconda3\Scripts\conda.exe

(base) C:\Users\MichaelGalarnyk>where python
C:\Users\MichaelGalarnyk\Anaconda3\python.exe


(base) C:\Users\MichaelGalarnyk>
```

Environnement 'Installation d'anaconda';

4. Ajoutez conda et python à votre PATH. Vous pouvez le faire en accédant à vos variables d'environnement et en ajoutant la sortie de l'étape 3 (enfermée dans le rectangle rouge) à votre chemin.



5. Ouvrez une nouvelle invite de commande. Essayez de saisir `conda --version` et `python --version` dans l'invite de commande pour vérifier si tout s'est bien passé.



```
Microsoft Windows [Version 10.0.16299.431]
(c) 2017 Microsoft Corporation. All rights reserved.

C:\Users\MichaelGalarnyk>conda --version
conda 4.4.10

C:\Users\MichaelGalarnyk>python --version
Python 3.6.4 :: Anaconda, Inc.

C:\Users\MichaelGalarnyk>
```

Interface du Jupyter Notebooks 'Comment utiliser';

Le Jupyter Notebook (anciennement appelé IPython Notebook) est une application Web qui vous permet de créer et de partager des documents informatiques contenant :

- 1.Des codes dynamiques
- 2.Des équations
- 3.Des visualisations
- 4.Des textes narratifs.

Le Jupyter Notebook peut être utile pour diverses fonctions. Il s'agit notamment de l'apprentissage et de l'enseignement d'un langage de programmation tel que Python, ainsi que du stockage et du partage de données.


Étape 1 : démarrage du serveur Jupyter Notebook

Maintenant que vous avez installé la distribution Anaconda, commençons à apprendre les bases.

- Ouvrez l'application de terminal et accédez au dossier de votre choix.
- Choisissez un emplacement (le dossier ou le sous-dossier, si vous en avez créé un à cet effet) dans votre terminal et exécutez la commande suivante : **\$ jupyter notebook**

Cela devrait démarrer Jupyter. Votre navigateur vous redirigera ensuite vers l'URL suivante : <http://localhost:8888/tree>.


Votre écran devrait maintenant ressembler à ceci :



Étape 2 : création du Notebook

Maintenant que vous avez appris à démarrer le serveur de blocs-notes, il est temps d'explorer comment créer un véritable document Jupyter Notebook.


- Cliquez sur le bouton déroulant « Nouveau »
- Sélectionnez « Python 3 » dans la liste des options
- Cela créera un nouveau bloc-notes pour Python qui ressemblera à l'image ci-dessous.



Jupyter Notebooks 'Comment utiliser';

Étape 3 : Nommer du Notebook

- Vous pouvez modifier le nom du document en cliquant sur le texte « sans titre ».
- Après avoir nommé le fichier, enregistrez-le avec l'extension .ipynb.



Running en haut indique que le fichier est actuellement ouvert. Vous pouvez choisir de l'arrêter en cliquant sur le bouton Arrêter.





Étape 4 : Exécuter les cellules Notebook

Le bloc-notes est composé de cellules. La première cellule vide devient disponible juste après la création d'un nouveau bloc-notes.



Elle vous permet de saisir directement le code Python.

Vous pouvez exécuter le code dans cette cellule en cliquant sur le bouton Exécuter la cellule ou en appuyant sur **Shift + Return**.



Étape 5 : Ajout d'un texte explicatif


- Pour inclure un texte explicatif dans votre bloc-notes, vous devrez modifier le type de cellule de Code à Markdown comme indiqué dans l'image ci-dessous.
- Une fois le type de cellule modifié, vous pouvez saisir le code Markdown et compiler la cellule en appuyant sur les touches Maj + Retour.
- La cellule de l'éditeur Markdown sera désormais remplacée par le résultat obtenu.



Étape 6 : Modes Édition et Commande


Si une cellule est active, elle est généralement distinguée par deux modes :
le mode Commande et le mode Édition.

Si vous cliquez sur une cellule, elle s'ouvre généralement en mode Commande.
Ceci est indiqué par une marge de couleur bleue à gauche.

A screenshot of a Jupyter Notebook cell in Command mode. The cell has a blue vertical margin on the left. The code area contains the text 'In [1]: print('Hello World')' and the output area contains 'Hello World'.

```
In [1]: print('Hello World')
Hello World
```

Si vous cliquez sur la zone de code de la cellule, vous accédez au mode Édition. Ceci est
indiqué par une marge de couleur verte à gauche.


A screenshot of a Jupyter Notebook cell in Edit mode. The cell has a green vertical margin on the left. The code area contains the text 'In [1]: print('Hello World')' and the output area contains 'Hello World'.

```
In [1]: print('Hello World')
Hello World
```

Jupyter Notebooks 'Comment utiliser';

Appuyez sur ÉCHAP pour revenir au mode Commande.

Utilisez Aide → Raccourcis clavier pour obtenir un aperçu des fonctions disponibles dans les deux modes.



Étape 7 : points de contrôle

Une fonction utile du bloc-notes Jupyter est sa capacité à créer des points de contrôle. Un point de contrôle enregistre l'état actuel du bloc-notes, ce qui permet de le rétablir ultérieurement si des modifications ont été apportées au bloc-notes depuis la création du point de contrôle.


Pour créer un nouveau point de contrôle, vous pouvez utiliser l'option Enregistrer et point de contrôle du menu Fichier (Fichier → Enregistrer et point de contrôle). Cela crée un point de contrôle et enregistre le fichier du bloc-notes.

Si vous souhaitez revenir au point de contrôle ultérieurement, vous pouvez le faire en utilisant l'option Fichier → Revenir au point de contrôle.

Étape 8 : Exporter le notebooks

Vous pouvez exporter le bloc-notes en cliquant sur Fichier → Télécharger en tant qu'options.

Choisissez l'un des formats proposés dans la liste, allant de .ipynb à .pdf.



Résumé des raccourcis de commande du bloc-notes Jupyter

Les notebooks Jupyter disposent de quelques astuces clavier rapides qui vous permettent de travailler plus facilement. Voici quelques-unes des touches clés que vous devez connaître :

Naviguer dans le bloc-notes

- **Esc** : Basculer entre le mode édition et le mode commande dans une cellule
- **Enter** : Basculer vers le mode édition dans une cellule
- **Flèche haut/bas** : Déplacer vers la cellule au-dessus ou en dessous
- **A ou B** : Ajouter une nouvelle cellule au-dessus ou en dessous de la cellule actuelle
- **X** : Couper la cellule sélectionnée
- **C** : Copier la cellule sélectionnée
- **V** : Coller la cellule copiée ou coupée
- **D, D** (appuyer deux fois sur la touche D) : Supprimer la cellule sélectionnée
- **Z** : Annuler la dernière suppression de cellule
- **Shift** : Sélectionner plusieurs cellules à la fois

Modification des cellules

- **Tab** : Aide au code ou ajouter un retrait
- **shift + Tab** : Supprimer un retrait
- **Ctrl + /** : Créer ou supprimer un commentaire sur une ligne

Exécution de la cellule

- **Ctrl + Enter** : Exécuter la cellule actuelle
- **Alt + Enter** : Exécuter la cellule actuelle et en ajouter une nouvelle en dessous
- **00 (appuyer deux fois sur la touche 0)** : Redémarrer le moteur du bloc-notes
- **I, I (appuyer deux fois sur la touche I)** : Arrêter le moteur du notebook s'il est bloqué

Informations sur le noyau

- **I** - Arrêter le moteur s'il tourne trop longtemps
- **0, 0** (appuyer deux fois sur la touche 0) - Redémarrer le moteur
- **shift + M** : Combiner les cellules sélectionnées ensemble

Manipulation de données '**Pandas**';

Installation '**pip install pandas**'
{

— **Importation ()**

```
import pandas as pd.
```

— **Creation de dataframe1()**

```
Variable_nom = pd.DataFrame ()
```

— **Attribution de valeur()**

```
Variable_nom ['Nom'] = ['Onesime', 'cyrille', 'Michel', 'Aimee']
```

```
Variable_nom ['Nom'] = [23, 12, 34, 90]
```

```
Variable_nom ['Nom'] = ['Vrai', 'Faux', 'Faux', 'Vrai']
```

```
Print(Variable_nom)
```

}

Pratique : **‘Voir Jupyter Notebook’** ;

Link : ;

1
2
3
4
5
6
7
8
9
10
11
12
13
14

{ Séance 2()

‘Prétraitement et Exploration de données
“Preprocessing”’

}

Machine learning Pipeline review



Analyse exploratoire et pretraitement des données

Comprendre les données



Les données statistiques peuvent être divisées en **deux grandes catégories** : données **quantitatives** et données **qualitatives**.

Chacune de ces catégories a ses propres sous-types, caractéristiques, et contextes d'utilisation.

Les données quantitatives sont des données numériques qui mesurent la quantité ou l'ampleur d'une variable.

Les données quantitatives peuvent être subdivisées en deux types principaux :

Données Continues: Les données continues sont des valeurs numériques qui peuvent prendre une infinité de valeurs dans un intervalle donné.

Exemples :

- Température : 22.5°C, 36.7°C
- Taille : 165.5 cm, 180.2 cm
- Poids : 70.3 kg, 54.8 kg
- Temps : 4.76 secondes, 12.34 minutes

Données Qualitatives: Les données qualitatives, aussi appelées données catégorielles, décrivent des attributs ou des caractéristiques non numériques.

Les données qualitatives sont subdivisées en deux types principaux :

Données Nominales : Les données nominales sont des données qualitatives qui représentent des catégories sans ordre intrinsèque.

- **Exemples :**

- Couleur des cheveux : brun, blond, roux
- Genre : homme, femme, autre
- Type de produit : alimentaire, électronique, vestimentaire

- **Données Ordinales** : Les données ordinales sont des données qualitatives avec un ordre ou un rang significatif entre les catégories. Cependant, les écarts entre les catégories ne sont pas nécessairement égaux.

Exemples :

- Niveaux de satisfaction : satisfait, neutre, insatisfait
- Niveau d'éducation : primaire, secondaire, universitaire
- Classement de courses : premier, deuxième, troisième

Autre types de données

Images & videos, audios ...

Format de données

Les données peuvent être classifiées en trois grandes catégories selon leur organisation et leur format :

- les données structurées,
- semi-structurées
- non structurées.

Chacune de ces catégories présente des caractéristiques distinctes qui influencent la manière dont les données sont stockées, traitées et analysées.

Données Structurées: Les données structurées sont des données organisées de manière rigide et prévisible, généralement dans des formats tabulaires avec des lignes et des colonnes.

Exemple:

Nom	Age	Sexe	Taille /m	Poid /kg
KOMBA	25	M	1.80	72
Nzulu	54	F	1.52	65

Données Semi-Structurées :

Les données semi-structurées ne suivent pas strictement un modèle de données fixe, mais elles contiennent des balises ou des marqueurs pour séparer les éléments et faciliter leur organisation.

Ces données ne sont pas aussi rigides que les données structurées mais possèdent néanmoins une certaine forme de structure.

Les formats comme XML et JSON sont couramment utilisés pour stocker et échanger des données semi-structurées.

Données Semi-Structurées :

Exemple fichier JSON:

```
{ "building": "1007",  
  "coord": { "type": "Point",  
              "coordinates" : [-73.856077, 40.848447]  
            },  
  "street": "Morris Park Ave",  
  "zipcode": "10462"  
}
```

Données Non Structurées : Les données non structurées sont des données qui ne suivent aucun modèle fixe ou prévisible. Elles sont généralement stockées dans leur format brut et ne sont pas organisées selon un schéma ou une structure prédéfinie.

Exemples :

- Documents texte : rapports, articles, essais.
- Contenus multimédias : photos, vidéos, enregistrements audio.
- Publications sur les réseaux sociaux : tweets, publications Facebook, commentaires.

Exploration et analyse univariée

Traitement des valeurs manquantes

1. Suppression des données :

- Suppression des cas : Supprimer toutes les observations avec des valeurs manquantes.
 - Avantages : Simple à implémenter.
 - Inconvénients : Peut entraîner une perte importante de données

Traitement des valeurs manquantes

2. Suppression des variables : Supprimer les variables avec un grand nombre de valeurs manquantes.

- Avantages : Évite les biais introduits par des valeurs manquantes systématiques.
- Inconvénients : Perte d'informations potentiellement importantes.

Traitement des valeurs manquantes

Imputation des données :

- Imputation par la moyenne/médiane/mode :
 - Remplacer les valeurs manquantes par la moyenne (pour les variables quantitatives), la médiane ou la mode (pour les variables qualitatives).
 - Avantages : Simple à mettre en œuvre et maintient la taille de l'ensemble de données.
 - Inconvénients : Réduit la variance des données et peut introduire un biais.

Traitement des valeurs manquantes


- **Imputation par régression :**
 - Utiliser des modèles de régression pour prédire les valeurs manquantes en fonction des autres variables.
 - Avantages : Peut capturer les relations entre les variables et fournir des imputations plus précises.
 - Inconvénients : Complexe à implémenter et peut sous-estimer la variance des imputations.

Les valeurs aberrantes:

Les valeurs aberrantes, également appelées outliers, sont des observations dans un ensemble de données qui s'écartent significativement des autres observations.

Ces valeurs peuvent indiquer des variations inhabituelles, des erreurs de mesure ou des cas exceptionnels, et elles peuvent avoir un impact important sur les analyses statistiques et les modèles de données.

Les valeurs aberrantes:



Mesure de dispersion:

Les mesures de dispersion sont des statistiques qui décrivent l'étendue et la variabilité d'un ensemble de données.

Elles sont essentielles pour comprendre comment les données se distribuent autour de la mesure de tendance centrale (comme la moyenne ou la médiane).

Variance:

La variance mesure de la dispersion des données par rapport à la moyenne. Elle représente la moyenne des carrés des écarts par rapport à la moyenne.

Pour un ensemble de données $\{x_1, x_2, \dots, x_n\}$ avec une moyenne $\bar{x}$ tel que

$$\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i \quad (1)$$

la variance σ^2 est donnée par :

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2 \quad (2)$$

Variance:

Exemple :

Index	Valeurs
1	3
2	5
3	7
4	8
5	10

La moyenne des données est calculée comme suit :

$$\bar{x} = \frac{3 + 5 + 7 + 8 + 10}{5} = \frac{33}{5} = 6.6$$

Calcul de la variance :


$$\begin{aligned}\sigma^2 &= \frac{(3 - 6.6)^2 + (5 - 6.6)^2 + (7 - 6.6)^2 + (8 - 6.6)^2 + (10 - 6.6)^2}{5} \\ &= \frac{12.96 + 2.56 + 0.16 + 1.96 + 11.56}{5} = \frac{29.2}{5} = 5.84\end{aligned}$$

$$\sigma^2 = 5.84$$

Variance:

Exemple :

Index	Valeurs
1	3
2	5
3	7
4	8
5	10



Écart-type (Standard Deviation):

Racine carrée de la variance, l'écart-type ramène la mesure de la dispersion aux mêmes unités que les données initiales.

Il est obtenu par :

$$\sigma = \sqrt{\sigma^2} \quad (3)$$

$$\sigma = \sqrt{5.84} = 2.41$$

Mesure de tendance centrales

Les mesures de tendance centrale sont des valeurs qui représentent ou résument un ensemble de données en identifiant le point central ou typique de la distribution.

Elles fournissent des informations sur la valeur autour de laquelle les autres valeurs de l'ensemble de données ont tendance à se regrouper.

Moyenne (ou moyenne arithmétique)

La moyenne est la somme de toutes les valeurs divisée par le nombre de valeurs.

Elle est la mesure de tendance centrale la plus utilisée, surtout lorsqu'il n'y a pas de valeurs aberrantes qui pourraient la fausser.

Voir l'équation (1)

Médiane

La médiane est la valeur qui sépare la moitié supérieure des valeurs de la moitié inférieure dans un ensemble de données ordonné.

C'est une mesure particulièrement utile lorsqu'il y a des valeurs aberrantes, car elle n'est pas influencée par celles-ci comme la moyenne.

- Comment la trouver :
 - Pour un nombre impair de valeurs : La médiane est la valeur du milieu une fois les données triées.
 - Pour un nombre pair de valeurs : La médiane est la moyenne des deux valeurs du milieu.

Médiane

- Exemple :
 - Pour un ensemble de données impair : [3,5,7,8,10][3, 5, 7, 8, 10][3,5,7,8,10], les données triées sont déjà ordonnées, donc la médiane est 7.
 - Pour un ensemble de données pair : [3,5,7,8,10,12][3, 5, 7, 8, 10, 12][3,5,7,8,10,12], les valeurs centrales sont 7 et 8, donc la médiane est :

$$Mediane = \frac{7 + 8}{2} = 7.5$$

Mode

Le mode est la valeur qui apparaît le plus fréquemment dans un ensemble de données.

Un ensemble de données peut avoir un mode, plusieurs modes (bimodal, multimodal) ou aucun mode si toutes les valeurs sont uniques.

- Exemple :
 - Pour un ensemble de données $[3, 5, 7, 8, 10, 8, 8]$, le mode est 8, car il apparaît trois fois, plus souvent que les autres valeurs.

Analyse multivariée

L'analyse multivariée est une branche des statistiques qui examine et interprète des données impliquant plusieurs variables simultanément.

Elle englobe diverses techniques pour comprendre les relations entre plusieurs variables et comment ces variables interagissent entre elles.

La corrélation linéaire

La corrélation linéaire est une mesure statistique qui indique la force et la direction d'une relation linéaire entre deux variables.

Elle évalue dans quelle mesure deux variables quantitatives sont linéairement liées.

En d'autres termes, elle mesure à quel point les points sur un diagramme de dispersion se rapprochent d'une droite.

Coefficient de Corrélation de Pearson (r)

Le coefficient de corrélation linéaire le plus courant est le coefficient de corrélation de Pearson.

Il varie entre **-1** et **1** et est calculé à l'aide de la formule suivante :

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}} \quad (4)$$

Coefficient de Corrélation de Pearson (r)

Interprétation du Coefficient de Corrélation

- **$r=1$** : Corrélation linéaire positive parfaite (lorsque X augmente, Y augmente de manière proportionnelle).
- **$r=-1$** : Corrélation linéaire négative parfaite (lorsque X augmente, Y diminue de manière proportionnelle).
- **$r=0$** : Aucune corrélation linéaire
- **$0 < r < 1$** : Corrélation positive (les deux variables augmentent ensemble).
- **$-1 < r < 0$** : Corrélation négative (une variable augmente tandis que l'autre diminue).

Coefficient de Corrélation de Pearson (r)

Exemple : Tableau de Données Météorologiques

Jour	Humidité (%)	Température (°C)	Pluie (mm)	Vent (km/h)	Chaleur (°C)	Interprétation de r
1	80	25	10	5	28	r=1 : Corrélation linéaire positive parfaite (Température ↔ Chaleur)
2	70	20	0	15	25	r=0.8 : Corrélation positive (Humidité ↔ Pluie)
3	60	22	5	20	27	r=0 : Aucune corrélation linéaire (Vent ↔ Température)
4	40	30	0	25	32	r=-0.7 : Corrélation négative (Température ↔ Humidité)
5	20	35	0	30	35	r=-1 : Corrélation linéaire négative parfaite (Vent ↔ Pluie)

Matrice de corrélation

Une matrice de corrélation est un tableau rectangulaire qui affiche les coefficients de corrélation entre plusieurs variables.

Chaque cellule de la matrice représente le coefficient de corrélation entre deux variables spécifiques.

Cette matrice est utile pour comprendre la force et la direction des relations linéaires entre plusieurs variables en un seul coup d'œil.

Matrice de corrélation

Si on a trois variables X_1, X_2 , et X_3 , la matrice de corrélation r serait :

$$R = \begin{pmatrix} r_{11} & r_{12} & r_{13} \\ r_{21} & r_{22} & r_{23} \\ r_{31} & r_{32} & r_{33} \end{pmatrix} = \begin{pmatrix} 1 & r_{12} & r_{13} \\ r_{21} & 1 & r_{23} \\ r_{31} & r_{32} & 1 \end{pmatrix}$$

Ici, r_{ij} représente le coefficient de corrélation entre X_i et X_j .

Normalisation et Standardisation

La normalisation et la standardisation sont deux techniques couramment utilisées en statistique et en apprentissage automatique pour préparer les données avant de les utiliser dans des modèles.

Elles sont particulièrement utiles lorsque les caractéristiques (features) des données ont des échelles différentes.

1. Normalisation

La normalisation, aussi appelée mise à l'échelle min-max (Min-Max Scaling), consiste à redimensionner les valeurs des caractéristiques pour qu'elles se situent dans une plage spécifique, généralement $[0,1]$ ou $[-1,1]$.

Pour une valeur x_i dans un ensemble de données la normalisation est donnée par :

$$\acute{x} = \frac{x_i - \min(X)}{\max(X) - \min(X)} \quad (5)$$

x_i : La valeur initiale.

$\acute{x}$: La valeur normalisée.

$\min(X)$: La valeur minimale de la caractéristique.

$\max(X)$: La valeur maximale de la caractéristique.

Quand utiliser la normalisation ?

Lorsque les caractéristiques des données ont des plages différentes et que vous voulez les ramener à une échelle commune.

Souvent utilisée dans les algorithmes d'apprentissage automatique qui ne font pas d'hypothèses sur la distribution des données, comme les réseaux de neurones ou les méthodes de plus proches voisins (KNN).

2. Standardisation

La standardisation consiste à recentrer les données pour qu'elles aient une moyenne de 0 et une variance (ou écart-type) de 1. Cela transforme les données en une distribution normale centrée.

Pour une valeur x_i , la standardisation s'obtient par :

$$z = \frac{x_i - \mu}{\sigma} \quad (6)$$

x_i : La valeur initiale.

μ : La moyenne de la caractéristique.

σ : L'écart-type de la caractéristique.

z : La valeur standardisée.

Quand utiliser la standardisation ?

Lorsque les données suivent une distribution normale (ou sont supposées le faire).

Utile dans les algorithmes qui supposent ou sont sensibles à la distribution des données, comme la régression linéaire, les modèles de machine à vecteurs de support (SVM), et les algorithmes de clustering comme K-means.

Création et la sélection de caractéristiques (features)

La création et la sélection de caractéristiques (features) sont des étapes cruciales dans le pipeline de machine learning.

Elles influencent directement la performance et la précision des modèles.

1. Création de Caractéristiques

La création de caractéristiques implique la transformation des données brutes en un format plus utile pour les modèles de machine learning.

MÉTHODES COURANTES :

- **Extraction de Caractéristiques** : Créez des caractéristiques à partir de données existantes en utilisant des méthodes statistiques ou des
- **Encodage des Variables Catégorielles** : Transformez les variables catégorielles en numériques.(One-hot encoding, Label encoding, Ordinal encoding)
- **Création de Nouvelles Variables** : Combinez ou transformez les variables existantes. Exemples : Interaction entre variables, polynômes, logarithmes, etc.

2. Sélection de Caractéristiques

La sélection de caractéristiques consiste à choisir les variables les plus pertinentes pour le modèle, afin de réduire la complexité et améliorer la performance.

- **Régression Lasso** : Utilise la régularisation L1 pour effectuer la sélection de caractéristiques en réduisant les poids des caractéristiques non importantes à zéro.
- **Tests Statistiques** : Utilisez des tests statistiques (comme le test de chi-carré pour les variables catégorielles) pour évaluer l'importance des caractéristiques.
- **Corrélation** : Sélectionnez les caractéristiques en fonction de leur corrélation avec la variable cible.
- **Analyse en Composantes Principales (PCA)** : Réduit la dimensionnalité des données tout en préservant la variance.
- **t-Distributed Stochastic Neighbor Embedding (t-SNE)** : Réduit la dimensionnalité pour les visualisations en préservant les relations locales.

Pratique 2 : **‘Voir Jupyter Notebook’** ;

Link :

1
2
3
4
5
6
7
8
9
10
11
12
13
14

{ Séance 3()



}

‘Apprentissage Supervisé : Regression’

Apprentissage Supervisé

- Est une branche de l'apprentissage automatique (machine learning) qui consiste à **entraîner un modèle** à partir d'un **ensemble de données étiquetées**. Ces données contiennent à la fois des entrées (les caractéristiques) et des sorties (les résultats attendus).
- Cela signifie que chaque donnée d'entrée est associée à une sortie correcte (**appelée étiquette ou label**). Le modèle apprend à associer les entrées aux sorties correspondantes, afin de pouvoir ensuite faire des prédictions sur de nouvelles données.

Branches de l'apprentissage supervisé

1. **Classification** : Le but est de prédire une catégorie ou une classe à partir de données d'entrée.

Exemples :

- Prédire si un e-mail est un spam ou non.
- Classifier des images d'animaux en chien, chat, etc.

2. **Régression** : Ici, l'objectif est de prédire une valeur continue en fonction des données d'entrée.

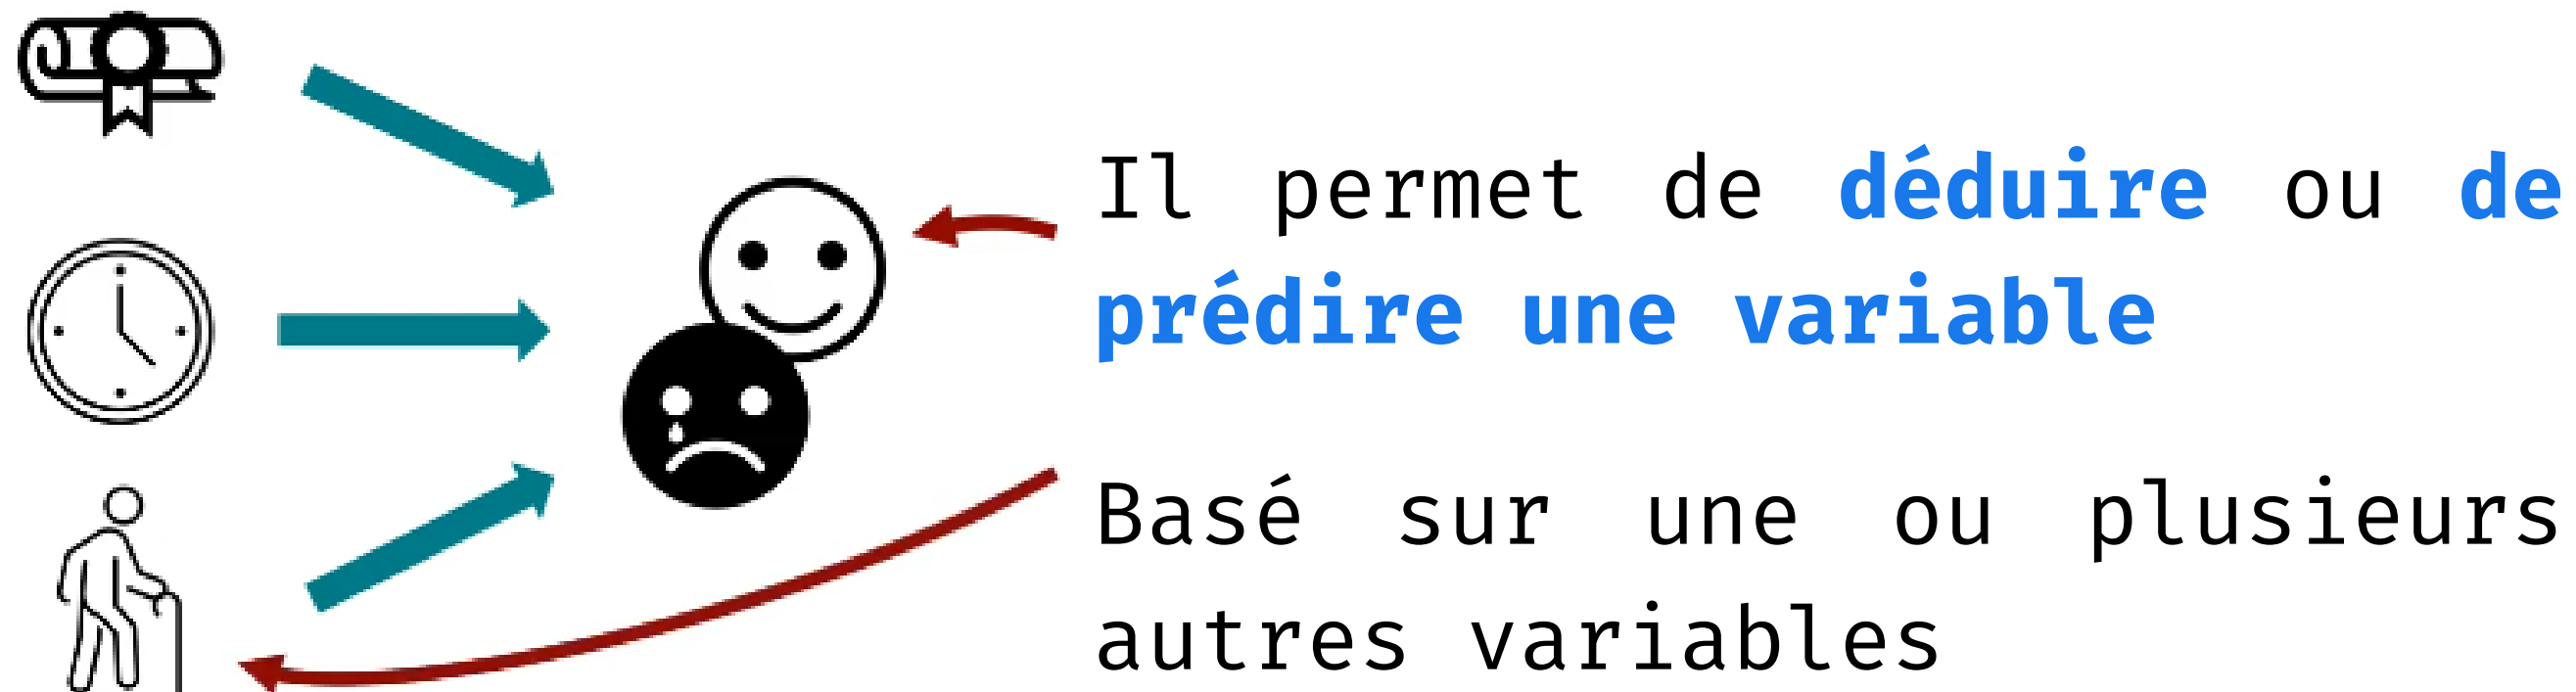
Exemples :

- Prédire le prix d'une maison en fonction de ses caractéristiques (taille, emplacement, etc.).
- Estimer les ventes futures d'un produit.

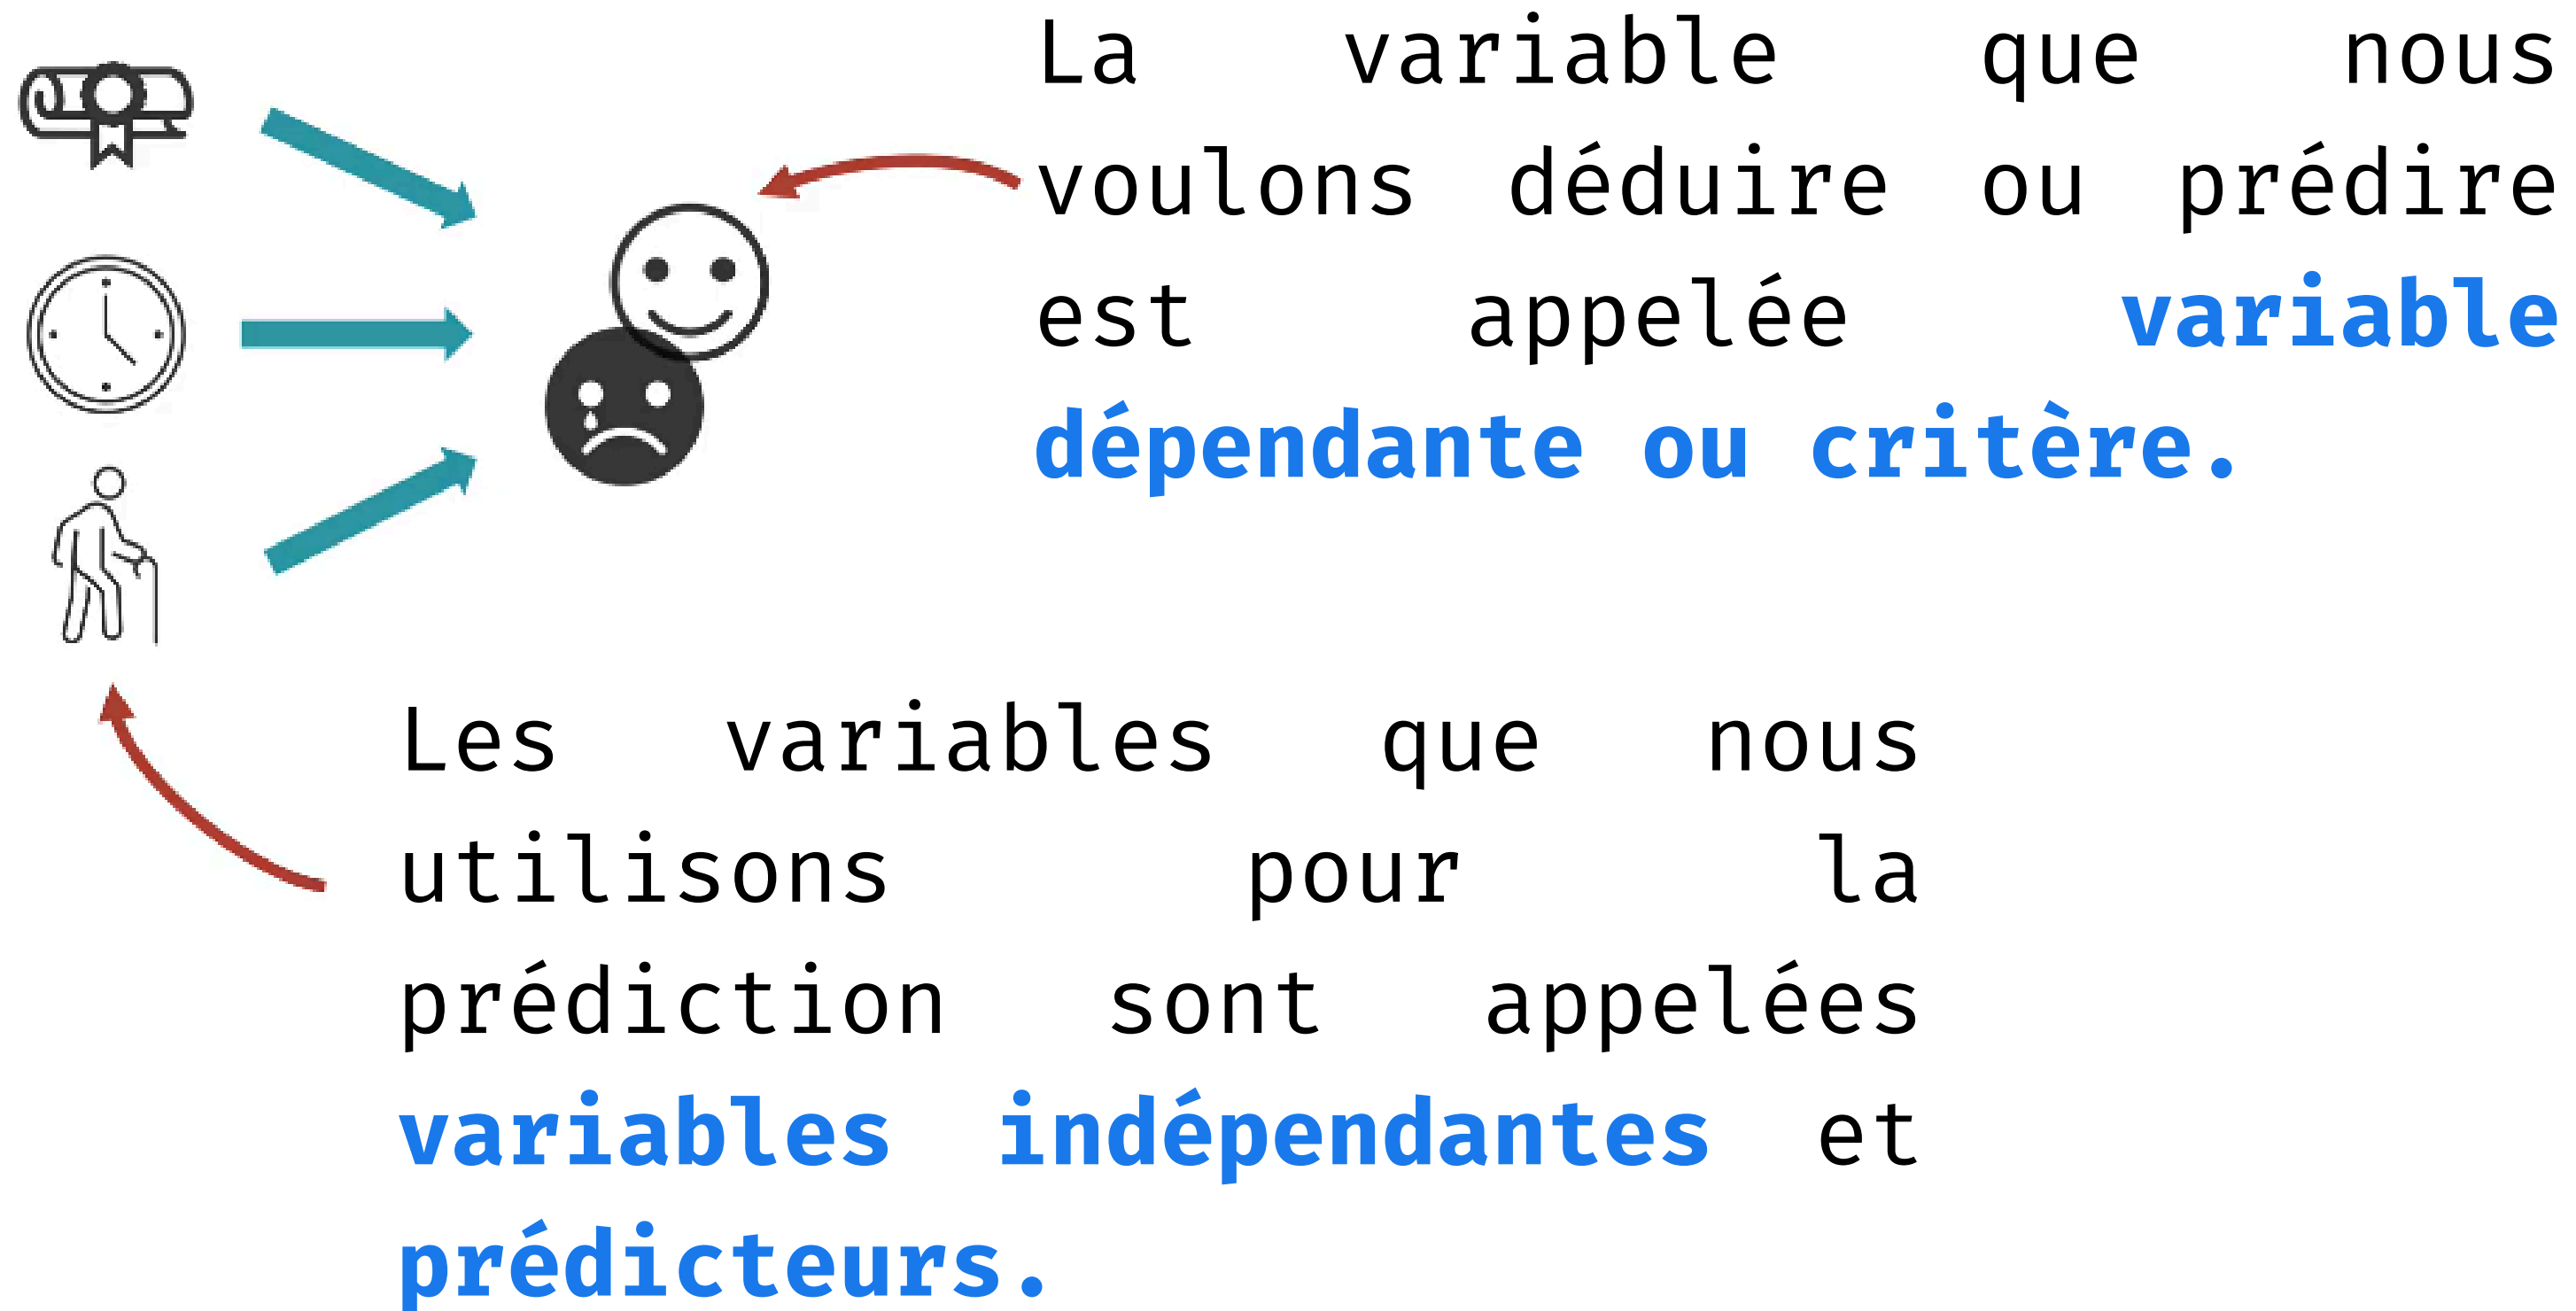
Dans ces deux cas, le modèle apprend en ajustant ses paramètres pour minimiser l'écart entre ses prédictions et les étiquettes réelles fournies dans les données d'entraînement.

Qu'est ce que la Regression ?






A regression analysis is a method for modeling relationships between variables



Qu'est ce que Regression ?



Difference entre la regression Linaire et la regression Logistique



Dans une **régression linéaire**, la variable dépendante est **une variable métrique**, par exemple le **salaire** ou **la consommation d'électricité**.


Dans une **régression logistique**, les variables dépendantes sont une **variable dichotomique**.

Qu'est-ce qu'un dichotomique

Les **variables dichotomiques** sont des variables avec seulement **deux valeurs**.

Par exemple :


si une personne **achète** ou **n'achète pas** un produit particulier.



si une maladie est présente ou non.


Qu'est-ce qu'un dichotomique

Ainsi, à l'aide de la **régression logistique**, nous pouvons déterminer ce qui a une influence sur **la présence ou non d'une certaine maladie**.



Qu'est-ce qu'un dichotomique

Dans ce cas, **0 signifie non malade** et **1 signifie malade**.




Et la **probabilité d'apparition de la caractéristique 1 (= caractéristique présente)** est estimée.

Qu'est-ce qu'un dichotomique

Ici nous avons **les variables indépendantes**

et ici **la variable dépendante** avec 0 et 1



Age	Gender	Smoker status	Disease
22	female	Non-smoker	1
25	female	Smoker	1
18	male	Smoker	0
45	male	Non-smoker	0
12	female	Smoker	0
43	male	Smoker	1
23	male	Smoker	0
33	male	Smoker	1
...	...	...	...

Nous pourrions maintenant étudier l'influence des variables indépendantes sur la maladie.

S'il y a une influence, nous pouvons alors **prédire** la probabilité qu'une personne soit atteinte d'une certaine maladie.

Qu'est-ce qu'un dichotomique

Pourquoi avons-nous besoin de régression logistique dans ce cas ?

Pourquoi ne pouvons-nous pas simplement utiliser une régression linéaire ?




Qu'est-ce qu'un dichotomique

Dans la régression linéaire, voici notre équation de régression

Nous avons la **variable dépendante**

Les **variables indépendante**



The diagram shows the linear regression equation $\hat{y} = b_1 \cdot x_1 + b_2 \cdot x_2 + \dots + b_k \cdot x_k + a$. A red arrow points from the text 'variable dépendante' to the predicted value $\hat{y}$. Four teal arrows point from the text 'Les variables indépendante' to the independent variables x_1, x_2, x_k . Two teal arrows point from the text 'Et les coefficients de régression' to the coefficients b_1 and b_2 .

$$\hat{y} = b_1 \cdot x_1 + b_2 \cdot x_2 + \dots + b_k \cdot x_k + a$$

Et les **coefficients de régression**

Classification vs Regression:

$$\mathcal{D} = \left\{ (\underline{x_i}, y_i)_{i=1}^n \mid x_i \in \mathbb{R}^d, y_i \in \{0, 1\} \right\}$$

$y_i \in \{0, 1\}$
 $\downarrow \quad \downarrow$
 $-ve \quad +ve$

$\swarrow$ Amazon Food reviews
 $\rightarrow$ 2 classes
 $\rightarrow$ 2 class - classification / Binary

MNIST: $\underline{y_i} \in \{0, 1, 2, 3, 4, 5, 6, 7, 8, 9\} \rightarrow$ 10-class / Multi-class
 classification

What if

$y_i \in \mathbb{R} \rightarrow$ regression problems

$\hookrightarrow y_i$ is no more part of a small finite set of classes

$i=1 \rightarrow 10k$

$x_i : \langle \text{Weight}, \text{age}, \text{gender}, \text{race} \rangle$

$y_i : \text{height}$

$\hookrightarrow$ real-number

$$y_i = \underline{f(x_i)}$$

182.6 cm, 152.7 cm,

K-NN for regression:

2-class
classifn

$$\mathcal{D} = \left\{ (x_i, y_i)_{i=1}^n \mid x_i \in \mathbb{R}^d, y_i \in \{0, 1\} \right\}$$

$f(x_q) \rightarrow y_q \rightarrow \text{class-label}$

✓ find
K-NN
Majority
rule

Regrsn

$$\mathcal{D} = \left\{ (x_i, y_i)_{i=1}^n \mid x_i \in \mathbb{R}^d; y_i \in \mathbb{R} \right\}$$

$x_q \rightarrow y_q \rightarrow \text{number}$

Some of the

extend

classfn $\rightarrow$ regrsn

① given (x_q) , find k -nearest neighbors
 $(x_1, y_1), (x_2, y_2) \dots (x_k, y_k)$

~~Class~~ $\rightarrow$ Majority vote

~~Regrsn~~

② y_q

$y_1, y_2, y_3 \dots y_k$ $\rightarrow$ not 0 or 1
 $(\mathbb{R})$

✓ { $y_q = \text{mean}(y_i)_{i=1}^k$ } $\left\{ \begin{array}{l} \text{regrsn:} \\ \text{Simple extension/modification of classn} \end{array} \right.$
 $y_q = \text{median}(y_i)_{i=1}^k \rightarrow \text{less prone to outliers}$

① given (x_q) , find k -nearest neighbors
 $(x_1, y_1), (x_2, y_2) \dots (x_k, y_k)$

~~Class~~ $\rightarrow$ Majority vote

~~Regrsn~~

② y_q

$y_1, y_2, y_3 \dots y_k$ $\rightarrow$ not 0 or 1
 $(\mathbb{R})$

✓ { $y_q = \text{mean}(y_i)_{i=1}^k$ } regn: Simple extension/modification of classn
 $y_q = \text{median}(y_i)_{i=1}^k \rightarrow$ less prone to outliers

① given (x_q) , find k -nearest neighbors
 $(x_1, y_1), (x_2, y_2) \dots (x_k, y_k)$

~~Class~~ $\rightarrow$ Majority vote

~~Regrsn~~


②

y_q

$y_1, y_2, y_3 \dots y_k$ $\rightarrow$ not 0 or 1
 $(\mathbb{R})$

✓ { $y_q = \text{mean}(y_i)_{i=1}^k$ } regn: Simple extension/modificⁿ of classⁿ
 $y_q = \text{median}(y_i)_{i=1}^k \rightarrow$ less prone to outliers


Geometry: e.g: predict height $\in \mathbb{R}$
 given wght, gender, ethnicity, hair color



Gr. regrsn: - find a line/plane
 that fits the
 given data

$$\left\{ \begin{array}{l} \text{height} = (w_1 \cdot \text{wght}) + (w_0) \\ y = \underline{\underline{m \cdot x + c}} \end{array} \right.$$

Gr. regrs



$$x_i = \begin{pmatrix} \text{weight} \\ \text{hair color} \end{pmatrix}$$


$$\text{height} = w_1 * f_1 + w_2 * f_2 + w_0$$

$$y_i = w_1 * x_{i1} + w_2 * x_{i2} + w_0$$

$$y_i = \mathbf{w}^T \mathbf{x}_i + w_0$$

find a line/plane that best fits the datapoints

best-fit
min error



$$y = f(x)$$

$$f(x) = \hat{w}_1 x + w_0$$

$$\text{error}_{f(x_1)} = y_1 - \hat{y}_1$$

$$\text{error}_{f(x_2)} = y_2 - \hat{y}_2$$

$$\begin{cases} f(x_1) = \hat{y}_1 \neq y_1 \\ f(x_2) = \hat{y}_2 \neq y_2 \end{cases}$$

Régression linéaire Simple(Prédiction manuelle)

Considérons un exemple où les données de ventes sur cinq semaines (en milliers) sont présentées sous forme de tableaux.

Xi (Semaine)	yi (Vente en dollard)
1	1200
2	1800
3	2600
4	3200
5	3800

Appliquer la technique de régression linéaire pour prédire les ventes des 7e et 12e semaines

Régression linéaire (Prédiction manuelle)

L'équation de régression linéaire est donnée par

$$y = a_0 + a_1 * x + e$$

où

$$a_1 = \frac{(\overline{xy}) - (\bar{x})(\bar{y})}{\overline{x^2} - \bar{x}^2}$$

$$a_0 = \bar{y} - a_1 * \bar{x}$$

Apprentissage Supervisé				
	X_i (Semaine)	y_i (Ventes)	x_i^2	$X_i * Y_i$
	1	1.2	1	1.2
	2	1.8	4	3.6
	3	2.6	9	7.8
	4	3.2	16	12.8
	5	3.8	25	19
Somme	15	12.6	55	44.4
Moyenne	$\text{moy}(x) = 3$	$\text{moy}(y) = 2.52$	$\text{moy}(x^2) = 11$	$\text{moyenne}(x*y) = 8.88$

$$\bar{x} = 3$$

$$\bar{y} = 2.52$$

$$\sum x^2 = 11$$

$$\overline{xy} = 8.88$$

$$a_1 = \frac{(\overline{xy}) - (\bar{x})(\bar{y})}{\sum x^2 - \bar{x}^2} = \frac{8.88 - 3 * 2.52}{11 - 3^2} = 0.66$$

$$a_0 = \bar{y} - a_1 * \bar{x} = 2.52 - 0.66 * 3 = 0.54$$

L'équation de régression est

$$y = a_0 + a_1 * x$$

$$y = 0.54 + 0.66 * x$$

La vente prévue pour la 7e semaine (quand $x = 7$) est

$$y = 0.54 + 0.66 \times 7 = 5.16$$

La vente prévue pour la 12e semaine (quand $x = 12$) est

$$y = 0.54 + 0.66 \times 12 = 8.46$$

Régression linéaire multiple(Prédiction manuelle)

Prédire la valeur de Y étant donné x1 et x2

SUBJECT	Y	X ₁	X ₂
1	-3.7	3	8
2	3.5	4	5
3	2.5	5	7
4	11.5	6	3
5	5.7	2	1
6	?	3	2

Régression linéaire multiple(Prédiction manuelle)

Prédire la valeur de Y étant donné x_1 et x_2

- Trouver la valeur de b (les pentes) est délicat pour $k > 2$ variables indépendantes, et vous avez vraiment besoin de l'algèbre de Marix pour voir le calcul
- À ce stade, vous devriez remarquer que tous les termes du cas à une variable apparaissent dans le cas à deux variables.
- Dans le cas à deux variables, les autres variables X apparaissent également dans l'équation. Par exemple, X_2 apparaît dans l'équation pour $b_1.s$.

Régression linéaire multiple (Prédiction manuelle)

Idée : examiner la relation linéaire entre 1 variable dépendante (y) et 2 ou plusieurs variables indépendantes (x_i)

Modèle de régression linéaire multiple avec k variables indépendantes :

$$Y = \beta_0 + \beta_1 X_1 + \beta_2 X_2 + \dots + \beta_k X_k + \epsilon$$

Y-intercept

Population slopes

Random Error

Régression linéaire à 2 variables indépendantes

a-intercept

$$a = \bar{Y} - b_1 \bar{X}_1 - b_2 \bar{X}_2$$

$$b_1 = \frac{(\sum x_2^2)(\sum x_1 y) - (\sum x_1 x_2)(\sum x_2 y)}{(\sum x_1^2)(\sum x_2^2) - (\sum x_1 x_2)^2}$$

$$b_2 = \frac{(\sum x_1^2)(\sum x_2 y) - (\sum x_1 x_2)(\sum x_1 y)}{(\sum x_1^2)(\sum x_2^2) - (\sum x_1 x_2)^2}$$

$$\sum x_1^2 = \sum X_1 X_1 - \frac{(\sum X_1)(\sum X_1)}{N}$$

$$\sum x_2^2 = \sum X_2 X_2 - \frac{(\sum X_2)(\sum X_2)}{N}$$

$$\sum x_1 y = \sum X_1 Y - \frac{(\sum X_1)(\sum Y)}{N}$$

$$\sum x_2 y = \sum X_2 Y - \frac{(\sum X_2)(\sum Y)}{N}$$

$$\sum x_1 x_2 = \sum X_1 X_2 - \frac{(\sum X_1)(\sum X_2)}{N}$$

Régression linéaire à 2 variables indépendantes

SUBJECT	Y	X ₁	X ₂	X ₁ X ₁	X ₂ X ₂	X ₁ X ₂	X ₁ Y	X ₂ Y
1	-3.7	3	8	9	64	24	-11.1	-29.6
2	3.5	4	5	16	25	20	14	17.5
3	2.5	5	7	25	49	35	12.5	17.5
4	11.5	6	3	36	9	18	69	34.5
5	5.7	2	1	4	1	2	11.4	5.7
Σ	19.5	20	24	90	148	99	95.8	45.6

Régression linéaire à 2 variables indépendantes

$$\sum x_1^2 = \sum X_1 X_1 - \frac{(\sum X_1)(\sum X_1)}{N} = 10$$

$$\sum x_2^2 = \sum X_2 X_2 - \frac{(\sum X_2)(\sum X_2)}{N} = 32.8$$

$$\sum x_1 y = \sum X_1 Y - \frac{(\sum X_1)(\sum Y)}{N} = 17.8$$

$$\sum x_2 y = \sum X_2 Y - \frac{(\sum X_2)(\sum Y)}{N} = -48$$

$$\sum x_1 x_2 = \sum X_1 X_2 - \frac{(\sum X_1)(\sum X_2)}{N} = 3$$

Régression linéaire à 2 variables indépendantes

$$\sum x_1^2 = \sum X_1 X_1 - \frac{(\sum X_1)(\sum X_1)}{N} = 10$$

$$\sum x_2^2 = \sum X_2 X_2 - \frac{(\sum X_2)(\sum X_2)}{N} = 32.8$$

$$\sum x_1 y = \sum X_1 Y - \frac{(\sum X_1)(\sum Y)}{N} = 17.8$$

$$\sum x_2 y = \sum X_2 Y - \frac{(\sum X_2)(\sum Y)}{N} = -48$$

$$\sum x_1 x_2 = \sum X_1 X_2 - \frac{(\sum X_1)(\sum X_2)}{N} = 3$$

Régression linéaire à 2 variables indépendantes

$$b_1 = \frac{(\sum x_2^2)(\sum x_1 y) - (\sum x_1 x_2)(\sum x_2 y)}{(\sum x_1^2)(\sum x_2^2) - (\sum x_1 x_2)^2} = \frac{32.8 * 17.8 - 3 * (-48)}{10 * 32.8 - 3 * 3} = 2.28$$

$$b_2 = \frac{(\sum x_1^2)(\sum x_2 y) - (\sum x_1 x_2)(\sum x_1 y)}{(\sum x_1^2)(\sum x_2^2) - (\sum x_1 x_2)^2} = \frac{10 * (-48) - 3 * 17.8}{10 * 32.8 - 3 * 3} = -1.67$$

$$a = \bar{Y} - b_1 \bar{X}_1 - b_2 \bar{X}_2 = \frac{19.5}{5} - \frac{2.28 * 20}{5} - \frac{-1.67 * 24}{5} = 2.796$$

Régression linéaire à 2 variables indépendantes

L'équation ou le modèle de régression final est :

$$Y = 2.796 + 2.28 x_1 - 1.67 x_2$$

Soit maintenant $X_1=3$ et $x_2= 2$ $y=?$

$$\begin{aligned} Y &= 2.796 + 2.28 * 3 - 1.67 * 2 \\ &= 6.296 \end{aligned}$$

Exemple de régression linéaire multivariée : **par** **approche matricielle**

La régression multiple de deux variables x_1 et x_2 est donnée comme suit :

$$y = f(x_1, x_2)$$

$$y = a_0 + a_1x_1 + a_2x_2$$

En général, elle est donnée pour n variables indépendantes comme suit :

$$y = f(x_1, x_2, \dots, x_n)$$

$$y = a_0 + a_1x_1 + a_2x_2 + \dots + a_nx_n + \varepsilon$$

Exemple de régression linéaire multivariée : **par** **approche matricielle**

Ici, les matrices pour Y et X sont données comme suit

$$X = \begin{pmatrix} 1 & 1 & 4 \\ 1 & 2 & 5 \\ 1 & 3 & 8 \\ 1 & 4 & 2 \end{pmatrix} \text{ et } Y = \begin{pmatrix} 1 \\ 6 \\ 8 \\ 12 \end{pmatrix}$$

x1 Product 1 Sales	x2 Product 2 Sales	Y Weekly Sales
1	4	1
2	5	6
3	8	8
4	2	12

Exemple de régression linéaire multivariée : **par** **approche matricielle**

Le coefficient de l'équation de régression multiple est donné comme

$$a = \begin{pmatrix} a_0 \\ a_1 \\ a_2 \end{pmatrix}.$$

Le coefficient de régression pour la régression multiple est calculé de la même manière que la régression linéaire simple

$$\hat{a} = ((X^T X)^{-1} X^T) Y$$

Exemple de régression linéaire multivariée : par approche matricielle

$$X^T X = \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 \\ 4 & 5 & 8 & 2 \end{pmatrix} \begin{pmatrix} 1 & 1 & 4 \\ 1 & 2 & 5 \\ 1 & 3 & 8 \\ 1 & 4 & 2 \end{pmatrix} = \begin{pmatrix} 4 & 10 & 19 \\ 10 & 30 & 46 \\ 19 & 46 & 109 \end{pmatrix}$$

$$(X^T X)^{-1} = \begin{pmatrix} 4 & 10 & 19 \\ 10 & 30 & 46 \\ 19 & 46 & 109 \end{pmatrix}^{-1} = \begin{pmatrix} 3.15 & -0.59 & -0.30 \\ -0.59 & 0.20 & 0.016 \\ -0.30 & 0.016 & 0.054 \end{pmatrix}$$

Exemple de régression linéaire multivariée : par approche matricielle

$$(X^T X)^{-1} X^T = \begin{pmatrix} 3.15 & -0.59 & -0.30 \\ -0.59 & 0.20 & 0.016 \\ -0.30 & 0.016 & 0.054 \end{pmatrix} \times \begin{pmatrix} 1 & 1 & 1 & 1 \\ 1 & 2 & 3 & 4 \\ 4 & 5 & 8 & 2 \end{pmatrix} = \begin{pmatrix} 0.05 & 0.47 & -1.02 & 0.19 \\ -0.32 & -0.098 & 0.155 & 0.26 \\ -0.065 & 0.005 & 0.185 & -0.125 \end{pmatrix}$$

$$\hat{a} = ((X^T X)^{-1} X^T) Y = \begin{pmatrix} 0.05 & 0.47 & -1.02 & 0.19 \\ -0.32 & -0.098 & 0.155 & 0.26 \\ -0.065 & 0.005 & 0.185 & -0.125 \end{pmatrix} \times \begin{pmatrix} 1 \\ 6 \\ 8 \\ 12 \end{pmatrix} = \begin{pmatrix} -1.69 \\ 3.48 \\ -0.05 \end{pmatrix}$$

Exemple de régression linéaire multivariée : **par** **approche matricielle**

$$a_0 = -1.69$$

$$a_1 = 3.48$$

$$a_2 = -0.05$$

$$y = a_0 + a_1x_1 + a_2x_2$$

Par conséquent, le modèle construit est

$$y = -1.69 + 3.48x_1 - 0.05x_2$$

Pratique 3 : **‘Voir Jupyter Notebook’ ;**

Link :

1
2
3
4
5
6
7
8
9
10
11
12
13
14

{ Séance 4()

‘Apprentissage Supervisé : Classification’

}

L'apprentissage supervisé : classification

Est une branche majeure du machine learning qui vise à construire des modèles capables de prédire à quelle classe appartient une nouvelle donnée, en se basant sur des exemples étiquetés.

Théories sous-jacentes

Pour comprendre en profondeur cette théorie, il est essentiel de maîtriser les concepts suivants :

L'apprentissage supervisé : classification

1. Théorie des probabilités et statistique

- **Distribution de probabilité:** Permet de modéliser l'incertitude associée aux données.
- **Estimation paramétrique et non paramétrique:** Méthodes pour estimer les paramètres d'un modèle à partir de données.
- **Tests d'hypothèses:** Pour évaluer la significativité des résultats obtenus.

L'apprentissage supervisé : classification

2. Optimisation

- **Fonction de coût:** Mesure la performance d'un modèle.
- **Algorithmes d'optimisation:** (descente de gradient, Newton-Raphson, etc.) permettent de trouver les paramètres du modèle qui minimisent la fonction de coût.

L'apprentissage supervisé : classification

3. Espaces vectoriels et algèbre linéaire

- **Représentation des données:** Les données sont souvent représentées sous forme de vecteurs dans un espace vectoriel.
- **Transformations linéaires:** Utilisées pour extraire des caractéristiques pertinentes des données.
-

L'apprentissage supervisé : classification

4. Théorie de l'information

- **Entropie:** Mesure l'impureté d'une distribution de probabilité.
- **Gain d'information:** Utilisé pour sélectionner les meilleures caractéristiques lors de la construction d'un arbre de décision.

L'apprentissage supervisé : classification

Concepts clés en classification supervisée

- **Ensemble d'entraînement:** Un ensemble de données étiquetées utilisé pour entraîner le modèle.
- **Ensemble de test:** Un ensemble de données étiquetées utilisé pour évaluer la performance du modèle.
- **Caractéristiques:** Les attributs utilisés pour décrire les données.
- **Classes:** Les étiquettes possibles que le modèle doit prédire.

L'apprentissage supervisé : classification

Concepts clés en classification supervisée

- **Modèle:** Une représentation mathématique de la relation entre les caractéristiques et les classes.
- **Sur-apprentissage:** Un modèle trop complexe qui mémorise les données d'entraînement au lieu de généraliser.
- **Sous-apprentissage:** Un modèle trop simple qui ne capture pas les complexités des données.

L'apprentissage supervisé : classification

Algorithmes de classification populaires

- **K-plus proches voisins (K-NN):** Classifie une nouvelle donnée en fonction de la classe majoritaire parmi ses k plus proches voisins.
- **Arbres de décision:** Créent une structure arborescente de décisions pour classer les données.
- **Forêts aléatoires:** Ensemble d'arbres de décision qui réduisent le risque de sur-apprentissage.

L'apprentissage supervisé : classification

Algorithmes de classification populaires

- **Machines à vecteurs de support (SVM):** Cherchent à trouver l'hyperplan qui sépare au mieux les différentes classes.
- **Réseaux de neurones artificiels:** Inspirés du cerveau, ils sont capables d'apprendre des représentations complexes des données.

L'apprentissage supervisé : classification

Évaluation des modèles de classification

- **Matrice de confusion:** Tableau qui résume les performances d'un modèle de classification.
- **Précision:** Proportion d'exemples correctement classés parmi ceux prédits positifs.
- **Rappel:** Proportion d'exemples positifs correctement identifiés.

L'apprentissage supervisé : classification

Évaluation des modèles de classification

- **F1-score:** Moyenne harmonique de la précision et du rappel.
- **Courbe ROC:** Représentation graphique de la performance d'un modèle de classification pour différents seuils de décision.

K-nearest neighbors (KNN): k plus proches voisins

- Est un algorithme d'apprentissage automatique supervisé parmi les plus simples à comprendre et à mettre en œuvre.
- Son principe de base repose sur une idée intuitive : **des objets similaires se trouvent à proximité les uns des autres.**

K-nearest neighbors (KNN): Comment fonctionne-t-il?

1. Phase d'apprentissage :

- L'algorithme stocke l'ensemble des données d'entraînement, chacune associée à une étiquette (la classe à laquelle elle appartient).
- Ces données sont généralement représentées sous forme de points dans un espace multidimensionnel, chaque dimension correspondant à une caractéristique.

K-nearest neighbors (KNN): Comment fonctionne-t-il?

2. Phase de prédiction :

Lorsqu'on souhaite classer un nouveau point (appelé point de requête), l'algorithme :

- Calcule la distance entre ce nouveau point et tous les points de l'ensemble d'entraînement.
- Identifie les k plus proches voisins du point de requête.
- Attribue au point de requête la classe qui est la plus fréquente parmi ses k plus proches voisins.


K-nearest neighbors (KNN): Comment fonctionne-t-il?

Distance euclidienne:

$$\| \cdot \|_2 = \sqrt{x^2 + y^2}$$

Où: $x = a - b$ et $y = c - d$

Si on prend deux points au hasard de coordonnées (a, c) et (b, d) .



K-nearest neighbors (KNN): Comment fonctionne-t-il?

Choisir le bon k

Le choix de la valeur de k est crucial :

- k trop petit: Le modèle sera très sensible au bruit dans les données.
- k trop grand: Le modèle risque de perdre en précision, car il généralisera trop.

Il n'existe pas de valeur de k optimale universelle. Elle doit être déterminée en fonction des données et du problème à résoudre, souvent par des techniques de validation croisée.

K-nearest neighbors (KNN): Comment fonctionne-t-il?

1. Les avantages de KNN

- Simple à comprendre et à mettre en œuvre.
- Pas besoin d'entraînement complexe.
- Flexible: Peut être utilisé pour la classification et la régression.


K-nearest neighbors (KNN): Comment fonctionne-t-il?

2. Les inconvénients de KNN

- Peu efficace sur de grands ensembles de données: Le calcul des distances peut être coûteux en temps.
- Sensible au choix de la métrique de distance: La distance euclidienne est souvent utilisée, mais d'autres métriques peuvent être plus adaptées selon les données.
- Sensible aux données déséquilibrées: Si une classe est largement majoritaire, elle aura tendance à dominer les prédictions.


K-nearest neighbors (KNN): Exemple

Taille (cm)	Poids (kg)	Classe
167	51	Anormal
182	62	Normal
176	69	Normal
173	64	Normal
172	65	Normal
174	56	Anormal
169	58	Normal
173	57	Normal
170	55	Normal
170	57	?



K-nearest neighbors (KNN): Exemple

Taille (cm)	Poids (kg)	Classe
167	51	Anormal
182	62	Normal
176	69	Normal
173	64	Normal
172	65	Normal
174	56	Anormal
169	58	Normal
173	57	Normal
170	55	Normal
170	57	?



K-nearest neighbors (KNN): Exemple

Taille (cm)	Poids (kg)	Classe
167	51	Anormal
182	62	Normal
176	69	Normal
173	64	Normal
172	65	Normal
174	56	Anormal
169	58	Normal
173	57	Normal
170	55	Normal
170	57	?

THE DISTANCE FORMULA

$$d = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

$$d_1 = \sqrt{(170 - 167)^2 + (57 - 51)^2}$$

$$d_2 = \sqrt{(170 - 182)^2 + (57 - 62)^2}$$

K-nearest neighbors (KNN): Exemple

Taille (cm)	Poids (kg)	Classe	Distance	Rank
167	51	Anormal	1,	1
182	62	Normal	2	2
176	69	Normal	3	3
173	64	Normal	4,1	4
172	65	Normal	6,7	5
174	56	Anormal	7,6	6
169	58	Normal	8,2	7
173	57	Normal	13	8
170	55	Normal	13,4	9
170	57	?		

- si K= 1, prediction sera Anormale
- si K= 2, prediction sera Normale
- si K= 3, prediction sera Normale
- si K= 4, prediction sera Normale
- si K= 5, prediction sera Normale

Régression Logistique

Est un algorithme d'apprentissage supervisé utilisé en statistique et en apprentissage automatique. Contrairement à ce que son nom pourrait laisser penser, elle ne sert pas à prédire des valeurs numériques continues comme la régression linéaire, mais plutôt à prédire l'appartenance d'une observation à une classe particulière. C'est donc un outil de classification.

Régression Logistique: Comment fonctionne-t-il?

1. Modélisation d'une probabilité:

- a. Au lieu de prédire directement une valeur, la régression logistique estime la probabilité qu'une observation appartienne à une classe particulière. Cette probabilité est comprise entre 0 et 1.
- b. Pour ce faire, elle utilise une fonction logistique (ou sigmoïde) qui transforme une combinaison linéaire des variables prédictives en une probabilité.

Régression Logistique: Comment fonctionne-t-il?

2. Seuil de décision:

- a. Une fois la probabilité calculée, on définit un seuil (souvent 0.5) pour décider de la classe à laquelle affecter l'observation.
- b. Si la probabilité est supérieure au seuil, l'observation est classée dans la classe positive. Sinon, elle est classée dans la classe négative.


Exemple: Régression Logistique

Une fois la probabilité calculée, on définit un seuil (souvent 0.5) pour décider de la classe à laquelle affecter l'observation. Si la probabilité est supérieure au seuil, l'observation est classée dans la classe positive. Sinon, elle est classée dans la classe négative.

Régression Logistique : Exemple

Ici nous avons **les variables indépendantes**

et ici **la variable dépendante** avec 0 et 1



Age	Gender	Smoker status	Disease
22	female	Non-smoker	1
25	female	Smoker	1
18	male	Smoker	0
45	male	Non-smoker	0
12	female	Smoker	0
43	male	Smoker	1
23	male	Smoker	0
33	male	Smoker	1
...	...	...	...


Nous pourrions maintenant étudier l'influence des variables indépendantes sur la maladie.

S'il y a une influence, nous pouvons alors **prédire** la probabilité qu'une personne soit atteinte d'une certaine maladie.

Régression Logistique : Exemple

Ici nous avons **les variables indépendantes**

et ici **la variable dépendante** avec 0 et 1




Age	Gender	Smoker status	Disease
22	female	Non-smoker	1
25	female	Smoker	1
18	male	Smoker	0
45	male	Non-smoker	0
12	female	Smoker	0
43	male	Smoker	1
23	male	Smoker	0
33	male	Smoker	1
...	...	...	...

Nous pourrions maintenant étudier l'influence des variables indépendantes sur la maladie.

S'il y a une influence, nous pouvons alors **prédire** la probabilité qu'une personne soit atteinte d'une certaine maladie.

Régression Logistique : Exemple



The diagram shows the logistic regression equation $\hat{y} = b_1 \cdot x_1 + b_2 \cdot x_2 + \dots + b_k \cdot x_k + a$. A red arrow points to the predicted value $\hat{y}$, which is enclosed in a red box. Three teal arrows point to the input features x_1 , x_2 , and x_k , each of which is enclosed in a teal box. The coefficients b_1 , b_2 , and b_k are not boxed.


$$\hat{y} = b_1 \cdot x_1 + b_2 \cdot x_2 + \dots + b_k \cdot x_k + a$$

Régression Logistique : Exemple

$$\hat{y} = b_1 \cdot x_1 + b_2 \cdot x_2 + \dots + b_k \cdot x_k + a$$

Cependant, nous avons maintenant une variable dépendante qui est soit 0, soit 1.

Quelle que soit la valeur que nous avons pour les variables indépendantes, seules 0 ou 1 en résultent.




Régression Logistique : Exemple

Cependant, l'objectif de la régression logistique est d'estimer la probabilité d'occurrence.


La plage de valeurs pour la prédiction doit donc être comprise entre 0 et 1.

Nous avons donc besoin d'une fonction qui ne prend que des valeurs comprises entre 0 et 1.




Régression Logistique : Exemple

Peu importe où nous nous trouvons sur l'axe des x , entre **moins** et **plus l'infini**, seules les valeurs comprises entre **0** et **1** en résultent.



Régression Logistique : Exemple

Pour Z , l'équation de régression linéaire est maintenant simplement utilisée.

$$\hat{y} = b_1 \cdot x_1 + b_2 \cdot x_2 + \dots + b_k \cdot x_k + a$$
$$f(z) = \frac{1}{1 + e^{-z}} = \frac{1}{1 + e^{-(b_1 \cdot x_1 + \dots + b_k \cdot x_k + a)}}$$


Cela nous donne
cette équation

Régression Logistique : Exemple

Ainsi, la **probabilité** que la variable dépendante soit 1 est donnée par cette équation pour des valeurs données des **variables indépendantes** :

$$P(y = 1|x_1, \dots, x_n) = \frac{1}{1 + e^{-(b_1 \cdot x_1 + \dots + b_k \cdot x_k + a)}}$$

Régression Logistique : Exemple

$$P(is\ diseased) = \frac{1}{1 + e^{-(b_1 \cdot Age + b_2 \cdot Male + b_3 \cdot Smoker + a)}}$$

Nous devons maintenant
déterminer les **coefficients**
afin que notre modèle
représente au mieux les données
données



Régression Logistique : Exemple

$$P(is\ diseased) = \frac{1}{1 + e^{-(b_1 \cdot Age + b_2 \cdot Male + b_3 \cdot Smoker + a)}}$$


Il nous faut maintenant déterminer les **coefficients** afin que notre modèle représente au mieux les données données.

Pour résoudre ce problème, on utilise la méthode dite du **maximum de vraisemblance**.

Pour cela, il existe de bonnes **méthodes numériques** qui permettent de résoudre efficacement le problème

Régression Logistique : Exemple

$$P(is\ diseased) = \frac{1}{1 + e^{-(b_1 \cdot Age + b_2 \cdot Male + b_3 \cdot Smoker + a)}}$$


L'entraînement du modèle vise à calculer les coefficients b_1 , b_2 , b_k et a

Régression Logistique : Exemple

$$P(is\ diseased) = \frac{1}{1 + e^{-(b_1 \cdot Age + b_2 \cdot Male + b_3 \cdot Smoker + a)}}$$


L'entraînement du modèle vise à calculer les coefficients b_1 , b_2 , b_k et a

Régression Logistique : Exemple

Le dataset sur **la réussite** ou **l'échec** à un examen de 5 étudiants est donné dans le tableau. Utilisez la régression logistique comme classificateur pour répondre aux questions suivantes.


1. Calculez la probabilité de **réussite** de **l'étudiant qui a étudié 33 heures**.

Régression Logistique : Exemple

Heures d'étude	Réussite (1) échec (0)
29	0
15	0
33	1
28	1
29	1

Supposons que le modèle suggéré par l'optimiseur pour les chances de réussite du cours soit,

Nous utilisons la fonction sigmoïde dans la régression logistique.



$$s(x) = \frac{1}{1+e^{-x}}$$

Régression Logistique : Exemple

2. Combien d'heures au moins l'étudiant doit-il étudier pour réussir le cours avec une probabilité de plus de 95 %.

$$p = \frac{1}{1+e^{-z}}$$

$$\log(odds) = z = -64 + 2 * hours$$

$$z = -64 + 2 * 33 = -64 + 66 = 2$$

$$p = \frac{1}{1+e^{-2}} = 0.88$$

Autrement dit, si l'étudiant étudie 33 heures, il y a 88 % de chances qu'il réussisse l'examen.

Matrice de confusion

Qu'est-ce qu'une matrice de confusion ?

Une matrice de confusion est un tableau qui permet de visualiser et d'évaluer la performance d'un modèle de classification. Elle compare les valeurs prédites par le modèle aux valeurs réelles. Chaque colonne de la matrice représente une classe prédite, et chaque ligne représente une classe réelle. Les cellules de la matrice indiquent le nombre d'observations qui ont été classées dans une certaine catégorie, alors qu'elles appartenaient en réalité à une autre.

Les principales métriques

- **Taux de vrais positifs (True Positive Rate, TPR) ou sensibilité:** Proportion d'observations positives correctement classées comme positives. C'est la capacité du modèle à identifier les cas positifs.
- **Taux de vrais négatifs (True Negative Rate, TNR) ou spécificité:** Proportion d'observations négatives correctement classées comme négatives. C'est la capacité du modèle à identifier les cas négatifs.
- **Taux de faux positifs (False Positive Rate, FPR):** Proportion d'observations négatives incorrectement classées comme positives.

Les principales métriques

- **Taux de faux négatifs (False Negative Rate, FNR):** Proportion d'observations positives incorrectement classées comme négatives.
- **Précision:** Proportion d'observations positives prédites qui sont effectivement positives.
- **Rappel:** Synonyme de sensibilité (TPR).
- **F1-score:** Moyenne harmonique de la précision et du rappel. C'est une mesure équilibrée qui pénalise les modèles qui ont soit une précision élevée, soit un rappel élevé, mais pas les deux.
- **Accuracy:** Proportion totale d'observations correctement classées.

Quand utiliser quelle métrique ?

Le choix de la métrique dépend du contexte et des objectifs de l'étude :

- **Sensibilité (TPR)**: Importante lorsque le coût d'un faux négatif est élevé (par exemple, dans le diagnostic médical).
- **Spécificité (TNR)**: Importante lorsque le coût d'un faux positif est élevé (par exemple, dans la détection des fraudes).
- **Précision**: Importante lorsque le coût d'un faux positif est élevé et qu'il est important de minimiser le nombre de faux positifs.

Quand utiliser quelle métrique ?

- **F1-score**: Utilisé lorsque l'on cherche un équilibre entre précision et rappel.
- **Accuracy**: Mesure globale de la performance, mais peut être trompeuse si les classes sont déséquilibrées.

Matrice de confusion

		Predicted Class		
		Positive	Negative	
Actual Class	Positive	True Positive (TP)	False Negative (FN) Type II Error	Sensitivity $\frac{TP}{(TP + FN)}$
	Negative	False Positive (FP) Type I Error	True Negative (TN)	Specificity $\frac{TN}{(TN + FP)}$
		Precision $\frac{TP}{(TP + FP)}$	Negative Predictive Value $\frac{TN}{(TN + FN)}$	Accuracy $\frac{TP + TN}{(TP + TN + FP + FN)}$

La validation croisée: Cross-Validation


Qu'est-ce que la validation croisée ?

La validation croisée est une technique statistique utilisée pour évaluer les performances d'un modèle de machine learning. Elle permet d'estimer la capacité généralisation du modèle, c'est-à-dire sa capacité à faire de bonnes prédictions sur de nouvelles données qu'il n'a pas encore vues pendant l'entraînement.

Pourquoi utiliser la validation croisée ?

- **Éviter le surapprentissage:** En divisant les données en plusieurs parties, on réduit le risque que le modèle apprenne par cœur les données d'entraînement et ne puisse pas généraliser.
- **Estimer la performance de manière plus robuste:** En évaluant le modèle sur différentes partitions des données, on obtient une estimation plus fiable de ses performances.

Méthodes de validation croisée



Méthodes de validation croisée

1. Validation Croisée k-fold

- **Principe:** Les données sont divisées en **k** sous-ensembles de taille égale. À chaque itération, un sous-ensemble est utilisé comme ensemble de test, tandis que les **k-1** autres sont utilisés pour entraîner le modèle. Cette procédure est répétée **k fois**, chaque sous-ensemble servant une fois comme ensemble de test.
- **Avantages:** Simple à implémenter, fournit une estimation robuste de la performance.
- **Inconvénients:** Peut être coûteux en calcul pour de grands ensembles de données.

Méthodes de validation croisée

2. Validation Croisée Stratifiée

- **Principe:** Assure que chaque fold a approximativement la même proportion de chaque classe, ce qui est important pour les problèmes de classification déséquilibrés.
- **Avantages:** Évite les biais dus à des distributions inégales des classes.
- **Inconvénients:** Peut être plus complexe à implémenter que la validation croisée k-fold.

Méthodes de validation croisée

3. Leave-One-Out Cross-Validation (LOOCV)

- **Principe:** Chaque observation est utilisée une fois comme ensemble de test.
- **Avantages:** Fournit une estimation précise de la performance, particulièrement pour de petits ensembles de données.
- **Inconvénients:** Très coûteuse en calcul pour de grands ensembles de données.

Méthodes de validation croisée

4. Validation Croisée Répétée

- **Principe:** La validation croisée k-fold est répétée plusieurs fois avec des partitions aléatoires différentes.
- **Avantages:** Fournit une estimation plus robuste de la performance, particulièrement pour de petits ensembles de données.
- **Inconvénients:** Peut être coûteuse en calcul.

Méthodes de validation croisée

5. Validation Croisée Time Series

- **Principe:** Conçue pour les données temporelles, où l'ordre des observations est important. Les données sont divisées en segments consécutifs pour éviter de mélanger des observations temporelles.
- **Avantages:** Appropriée pour les données séquentielles.
- **Inconvénients:** Peut être plus complexe à implémenter que les autres méthodes.

Méthodes de validation croisée

6. Validation Croisée Monte Carlo

- **Principe:** Les données sont échantillonnées aléatoirement avec remplacement pour créer plusieurs sous-ensembles d'entraînement et de test.
- **Avantages:** Flexible, peut être utilisée dans différentes situations.
- **Inconvénients:** Peut être moins robuste que les autres méthodes pour de petits ensembles de données.

Choix du nombre de folds (k)

Le choix du nombre de folds (k) est un compromis :

- **k petit**: Variance élevée des scores, mais moins coûteux en calcul.
- **k grand**: Variance faible des scores, mais plus coûteux en calcul.

En pratique, 5 ou 10 folds sont souvent utilisés.

Remember



Le choix de la méthode de validation croisée dépend du problème spécifique, de la taille de l'ensemble de données et des ressources disponibles. Il est important de choisir une méthode qui convient à la nature des données et aux objectifs de l'analyse.

Machine à vecteurs de support

- Support Vector Machine ou SVM est l'un des algorithmes d'apprentissage supervisé les plus populaires, utilisé pour les problèmes de classification et de régression.
- Cependant, il est principalement utilisé pour les problèmes de classification dans l'apprentissage automatique.
- L'objectif de l'algorithme SVM est de créer la meilleure ligne ou limite de décision qui puisse séparer l'espace n-dimensionnel en classes afin que nous puissions facilement placer le nouveau point de données dans la bonne catégorie à l'avenir.

Machine à vecteurs de support

- Il peut y avoir plusieurs lignes/limites de décision pour séparer les classes dans l'espace n-dimensionnel, mais nous devons trouver la meilleure limite de décision qui aide à classer les points de données.
- Cette meilleure limite est connue sous le nom **d'hyperplan SVM**



Machine à vecteurs de support

Le SVM est l'un des algorithmes d'apprentissage supervisé les plus populaires. Elle est utilisée pour les problèmes de classification et de régression.



- Cependant, elle est principalement utilisée pour les problèmes de classification dans l'apprentissage automatique.
- L'objectif de l'algorithme SVM est de créer la meilleure ligne ou limite de décision qui puisse séparer l'espace n -dimensionnel en classes afin que nous puissions facilement placer le nouveau point de données dans la bonne catégorie à l'avenir.

Machine à vecteurs de support

SVM- Hyperplan

- Il peut y avoir plusieurs lignes/limites de décision pour séparer les classes dans l'espace n-dimensionnel, mais nous devons trouver la meilleure limite de décision qui aide à classer les points de données.
- Cette meilleure limite est connue sous le nom d'hyperplan de SVM.

Machine à vecteurs de support



Machine à vecteurs de support



- La dimension de l'hyperplan dépend des entités présentes dans l'ensemble de données, ce qui signifie que s'il y a 2 entités (comme indiqué dans l'image), alors l'hyperplan sera une ligne droite.
- Et s'il y a 3 entités, alors l'hyperplan sera un plan à 2 dimensions.
- Nous créons toujours un hyperplan qui a une marge maximale, c'est-à-dire la distance maximale entre les points de données.

SVM – Types de SVM


SVM peut être de deux types :

- **SVM linéaire** : le SVM linéaire est utilisé pour les données séparables linéairement, ce qui signifie que si un ensemble de données peut être classé en deux classes à l'aide d'une seule ligne droite, ces données sont alors qualifiées de données séparables linéairement et le classificateur utilisé est appelé classificateur SVM linéaire.

Linear SVM



Linear SVM



$$\max \frac{2}{\|\vec{w}\|}$$

s.t.

$$(\vec{w} \cdot \vec{x} + b) \geq 1, \forall \vec{x} \text{ of class 1}$$

$$(\vec{w} \cdot \vec{x} + b) \leq -1, \forall \vec{x} \text{ of class 2}$$




SVM – Types de SVM

- **SVM non linéaire** : le SVM non linéaire est utilisé pour les données séparées de manière non linéaire, ce qui signifie que si un ensemble de données ne peut pas être classé à l'aide d'une ligne droite, ces données sont alors qualifiées de données non linéaires et le classificateur utilisé est appelé classificateur SVM non linéaire.

Non- Linear SVM

- Si les données sont organisées de manière linéaire, nous pouvons les séparer en utilisant une ligne droite, mais pour les données non linéaires, nous ne pouvons pas tracer une seule ligne droite.
- Ainsi, pour séparer ces données, nous devons ajouter une dimension supplémentaire.
- Pour les données linéaires, nous avons utilisé deux dimensions x et y , donc pour les données non linéaires, nous ajouterons une troisième dimension z .
- Elle peut être calculée comme $z = x^2 + y^2$

Non-Linear SVM



1
2
3
4
5
6
7
8
9
10
11
12
13
14

{ Séance 6()



‘Réseau de neurones’

}

Rappel calcul matriciel

Les calculs matriciels et vectoriels sont essentiels en le machine learning.

1. Calcul Vectoriel

Les vecteurs sont des objets mathématiques qui ont une magnitude (longueur) et une direction. Ils sont souvent représentés sous forme de colonnes ou de lignes.

Rappel calcul matriciel

a. Addition de Vecteurs

Soient deux vecteurs $\mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \end{pmatrix}$ et $\mathbf{u} = \begin{pmatrix} u_1 \\ u_2 \end{pmatrix}$. Leur addition est :

$$\mathbf{v} + \mathbf{u} = \begin{pmatrix} v_1 + u_1 \\ v_2 + u_2 \end{pmatrix}$$

Chaque composante est additionnée individuellement.

Rappel calcul matriciel

b. Multiplication par un scalaire

Multiplier un vecteur par un scalaire revient à multiplier chaque composante du vecteur par ce nombre. Si $\mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \end{pmatrix}$ et k est un scalaire, alors :

$$k\mathbf{v} = \begin{pmatrix} kv_1 \\ kv_2 \end{pmatrix}$$

Rappel calcul matriciel

c. Produit Scalaire (Dot Product)

Le produit scalaire entre deux vecteurs $\mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \end{pmatrix}$ et $\mathbf{u} = \begin{pmatrix} u_1 \\ u_2 \end{pmatrix}$ est donné par :

$$\mathbf{v} \cdot \mathbf{u} = v_1 u_1 + v_2 u_2$$

Le résultat est un scalaire.

Rappel calcul matriciel

2. Calcul Matriciel

Les matrices sont des tableaux de nombres arrangés en lignes et en colonnes. Elles permettent de représenter et résoudre des systèmes linéaires, entre autres.

a. Addition de Matrices

Si deux matrices A et B sont de la même taille, leur addition s'effectue élément par élément. Si

$$A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix} \text{ et } B = \begin{pmatrix} b_{11} & b_{12} \\ b_{21} & b_{22} \end{pmatrix}, \text{ alors :}$$

$$A + B = \begin{pmatrix} a_{11} + b_{11} & a_{12} + b_{12} \\ a_{21} + b_{21} & a_{22} + b_{22} \end{pmatrix}$$

Rappel calcul matriciel

b. Multiplication par un scalaire

Multiplier une matrice par un scalaire consiste à multiplier chaque élément de la matrice par ce scalaire. Si $A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}$ et k est un scalaire, alors :

$$kA = \begin{pmatrix} ka_{11} & ka_{12} \\ ka_{21} & ka_{22} \end{pmatrix}$$

Rappel calcul matriciel

c. Produit de Matrices

Le produit de deux matrices A (de taille $m \times n$) et B (de taille $n \times p$) donne une matrice C (de taille $m \times p$). L'élément c_{ij} de la matrice C est calculé comme suit :

$$C = AB \quad \text{où} \quad c_{ij} = \sum_{k=1}^n a_{ik} b_{kj}$$

Cela implique la somme des produits des éléments correspondants des lignes de A et des colonnes de B .

Rappel calcul matriciel

d. Multiplication Matrice-Vecteur

Une matrice peut être multipliée par un vecteur. Si $A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}$ est une matrice 2×2 et

$\mathbf{v} = \begin{pmatrix} v_1 \\ v_2 \end{pmatrix}$ est un vecteur, alors :

$$A\mathbf{v} = \begin{pmatrix} a_{11}v_1 + a_{12}v_2 \\ a_{21}v_1 + a_{22}v_2 \end{pmatrix}$$

Rappel calcul matriciel

e. Transposée d'une Matrice

La transposée d'une matrice $A = \begin{pmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{pmatrix}$ est obtenue en échangeant ses lignes et colonnes :

$$A^T = \begin{pmatrix} a_{11} & a_{21} \\ a_{12} & a_{22} \end{pmatrix}$$

Rappel calcul matriciel

Indix	X				Y
J	Humidité (%)	Température (°C)	Vent (km/h)	Chaleur (J/(kg.K))	Label (Pluie)
1	80	25	5	28	1
2	70	20	15	25	0
3	60	22	20	27	1
4	40	30	25	32	0
5	20	35	30	35	0

$$X = \{x^{(1)}, x^{(2)}, \dots, x^{(m)}, \dots, x^{(M)}\}$$

$$\text{Telque } X \in \mathbb{R}^{M \times N}$$

$$x^{(m)} = \{x_1^{(m)}, x_2^{(m)}, \dots, x_n^{(m)}, \dots, x_N^{(m)}\}$$

$$x^m \in \mathbb{R}^N$$

Exemple :

$$x^{(1)} = (80 \quad 25 \quad 5 \quad 28) = \begin{pmatrix} 80 \\ 25 \\ 5 \\ 28 \end{pmatrix}$$

$$x_1^{(1)} = 80; x_2^{(1)} = 25; x_3^{(1)} = 5; x_4^{(1)} = 28$$

Rappel calcul matriciel

Indix	X				Y
J	Humidité (%)	Température (°C)	Vent (km/h)	Chaleur (J/(kg.K))	Label (Pluie)
1	80	25	5	28	1
2	70	20	15	25	0
3	60	22	20	27	1
4	40	30	25	32	0
5	20	35	30	35	0

$$Y = \{y^{(1)}, y^{(2)}, \dots, y^{(m)}, \dots, y^{(M)}\}$$

$$Y \in \mathbb{R}^M$$


$$y^{(m)} = 1 \dots M \in \mathbb{R}$$

Exemple :

$$y^{(1)} = 1; y^{(2)} = 0$$

$$Y = \begin{pmatrix} 1 \\ 0 \\ 1 \\ 0 \\ 0 \end{pmatrix}$$


Etapes importantes de construction du modele



Etapes importantes de construction du modele



Entrainement du modele illustration



Exemple : Modele de Regresion Lineaire


$$y = \theta_0 + x.\theta_1$$

Le neurone artificiel

Un neurone artificiel est l'unité de base dans les réseaux de neurones, inspiré par le fonctionnement d'un neurone biologique.

En termes de modélisation mathématique, un neurone artificiel prend un ensemble d'entrées, les pondère, les combine, et applique une fonction d'activation pour produire une sortie.

Le neurone artificiel



Fonction de combinaison

$$Z = \sum w_{j,i}^{(m)} x_i^{(m)} + b_j^{(m)}$$

$$= (w_{11}^{(m)} * x_1^{(m)} + w_{12}^{(m)} * x_2^{(m)} + \dots + w_{1N}^{(m)} * x_N^{(m)}) + b_1^{(m)}$$

Avec calcul vectoriel

$$Z = W^T X + b$$

Fonction d'activation

$$\varphi = \frac{1}{1 + \exp^{-Z}}$$

Ici la fonction d'activation peut varier

Le neurone artificiel

Indix **X** **y**

J	Humidité (%)	Température (°C)	Vent (km/h)	Chaleur (J/(kg.K))	Label (Pluie)
1	80	25	5	28	1
2	70	20	15	25	0
3	60	22	20	27	1
4	40	30	25	32	0
5	20	35	30	35	0

Exemple :

$$x^{(m)} = \text{Jour1}; w_{11}^{(m)} = 0.5; w_{12}^{(m)} = 0.1; w_{13}^{(m)} = 0.014; w_{14}^{(m)} = 0.2$$

$$b_1^{(m)} = 1; y^{(m)} = 1$$

$$z = (0.5 * 80 + 0.1 * 25 + 0.014 * 5 + 0.2 * 28) + 1 = 49.14$$

$$\varphi = \frac{1}{1 + \exp^{-49.14}} = 1.0$$

Le neurone artificiel

Fonction coût (Cost Function)

La fonction coût mesure l'écart entre les prédictions du modèle et les valeurs réelles. C'est une mesure de la performance du modèle.

1. Erreur quadratique moyenne (MSE - Mean Squared Error) :

$$J(\theta) = \frac{1}{M} \sum_{m=1}^M (h_{\theta}(x^{(m)}) - y^{(m)})^2$$

Le neurone artificiel

1. Erreur quadratique moyenne (MSE – Mean Squared Error) :

$$J(\theta) = \frac{1}{M} \sum_{m=1}^M (h_{\theta}(x^{(m)}) - y^{(m)})^2$$

Où :

- $h_{\theta}(x^{(m)})$ est la prédiction du modèle pour l'entrée $x^{(m)}$,
- $y^{(m)}$ est la valeur réelle (étiquette) pour l'exemple m ,
- M est le nombre total d'exemples,
- θ représente les paramètres (poids) du modèle.

Le neurone artificiel

L'objectif est de minimiser cette fonction pour rendre les prédictions du modèle aussi précises que possible.

2. Fonction de coût logarithmique (Log Loss) pour la classification

$$J(\theta) = -\frac{1}{M} \sum_{m=1}^M [y^{(m)} \log(h_{\theta}(x^{(m)})) + (1 - y^{(m)}) \log(1 - h_{\theta}(x^{(m)}))]$$

Utilisée principalement pour les problèmes de classification binaire, où $y^{(m)} \in \{0, 1\}$.

Le neurone artificiel

Fonction d'erreur (Loss Function)



La fonction d'erreur, souvent utilisée de manière interchangeable avec la fonction coût, représente la différence entre la prédiction et la valeur cible pour un exemple particulier.

Pour chaque exemple, l'erreur est calculée, et la fonction coût est souvent la moyenne de ces erreurs sur l'ensemble des exemples.

Le neurone artificiel

Algorithme d'apprentissage (Gradient Descent Algorithm)

La descente de gradient est un algorithme d'optimisation utilisé pour minimiser la fonction coût en ajustant les paramètres du modèle.



$$f(x) = 4x^2 + 2x + 3$$

$$f'(x) = 8x + 2$$

$$f''(x) = 8$$

$$f'''(x) = 0$$

Le neurone artificiel

Processus de la descente de gradient :

1. Calcul du gradient :

Le gradient est le vecteur des dérivées partielles de la fonction coût par rapport à chaque paramètre. Il indique dans quelle direction et avec quelle intensité modifier les paramètres pour réduire l'erreur.

$$\frac{\partial J(\theta)}{\partial \theta_j}$$

Où θ_j est un paramètre spécifique du modèle.

Le neurone artificiel

2. Mise à jour des paramètres :

Les paramètres sont ajustés dans la direction opposée au gradient, ce qui permet de réduire la fonction coût.

Pour chaque itération, la règle de mise à jour des poids est :

$$\theta_j := \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j}$$

Le neurone artificiel

$$\theta_j := \theta_j - \alpha \frac{\partial J(\theta)}{\partial \theta_j}$$

Où :

- α est le **taux d'apprentissage** (learning rate), un hyperparamètre qui détermine la taille des pas de mise à jour,
- θ_j est un paramètre du modèle,
- $\frac{\partial J(\theta)}{\partial \theta_j}$ est la dérivée partielle de la fonction coût par rapport à θ_j .

3. **Itération** : Le processus de mise à jour est répété pour plusieurs itérations jusqu'à ce que la fonction coût atteigne un minimum ou que la réduction soit négligeable (convergence).

Le reseau des neurones artificiel

1
2
3
4
5
6
7
8
9
10
11
12
13
14

{

Séance 5()

}

‘Apprentissage Non-Supervisé : Clustering’

Qu'est-ce que le clustering ?

Le clustering est une technique non supervisée qui regroupe les données en différents clusters en fonction de leur similarité.

- Le cluster est un groupe de points de données qui sont similaires les uns aux autres.
- Comme il n'a pas de données étiquetées, il utilise les propriétés des données pour les regrouper.
- Les données d'un même cluster sont similaires les unes aux autres et différentes des données d'un autre cluster.

Qu'est-ce que le clustering ?

- Le clustering est utilisé pour la segmentation des clients et la segmentation des images.
- Le clustering est également utilisé dans l'apprentissage supervisé pour trouver les étiquettes des données non étiquetées du cluster auquel il appartient.

Types de clustering

Il existe deux types de clustering, le clustering souple et le clustering dur.

- **Soft Clustering** : il attribue la probabilité que les données d'entrée appartiennent à un certain cluster, plutôt que d'attribuer chaque donnée d'entrée à un cluster particulier.
- **Hard Clustering** : chaque donnée d'entrée appartient entièrement à un cluster particulier ou non.

Types d'algorithmes de clustering

- Il existe quatre principaux types d'algorithmes de clustering, basés sur la densité, basés sur la distribution, basés sur le centroïde et basés sur la hiérarchie.
- Basé sur la densité : dans ce cas, les données sont regroupées par zones de forte densité et de faible densité. Ces clusters peuvent être de n'importe quelle forme.

Types d'algorithmes de clustering

- Basé sur la distribution : les données sont divisées en fonction de la probabilité d'appartenance d'une donnée à une distribution particulière. Le regroupement est effectué en supposant une distribution gaussienne. Si la distribution des données est inconnue, cette méthode doit être évitée. Ces clusters peuvent être de n'importe quelle forme.
- Basé sur le centroïde : il crée un cluster basé sur le centroïde des données. Le point est attribué à un cluster avec le centroïde le plus proche. Il est basé sur la distance des points par rapport au centroïde. Ces clusters sont de forme circulaire.

Types d'algorithmes de clustering

- Basé sur la hiérarchie : ce type de clustering est utilisé pour les données hiérarchiques. Il construit un arbre de clusters. Il existe deux types d'approches, agglomérative et divisive. L'approche agglomérative est ascendante, dans laquelle l'algorithme commence par considérer chaque point de données comme un cluster unique et les fusionne jusqu'à ce qu'il ne reste qu'un seul cluster. L'approche divisive est descendante, dans laquelle l'algorithme considère tous les points de données comme étant dans un seul cluster, puis divise le cluster unique en plusieurs clusters.

Clustering : K-Means


- Le clustering K-means est un algorithme basé sur les centroïdes. Il regroupe les données en k clusters. Le nombre de clusters et le nombre de centroïdes doivent être choisis de manière aléatoire. L'objectif est de minimiser les distances entre les points de données des mêmes clusters et de maximiser la distance entre les différents clusters.
- Il est coûteux en termes de calcul pour les données volumineuses car il continue d'itérer sur toutes les données.

Clustering : K-Means

- Il trouve le meilleur ensemble de centroïdes qui minimise la somme des distances au carré entre chaque point de données et son centroïde le plus proche.
- Pour trouver le nombre optimal de clusters, la méthode du coude est utilisée. Elle trace la somme des distances euclidiennes au carré entre les points de données et leur centroïde et choisit le nombre de clusters où la variation de la somme des distances au carré commence à se stabiliser.


Clustering : K-Means

- Le clustering K-means est un algorithme de clustering non supervisé basé sur la distance où les points de données proches les uns des autres sont regroupés dans un nombre donné de clusters/groupes.



Clustering : K-Means


- Il nécessite de spécifier le nombre de clusters (k) à l'avance.
- De plus, nous devons sélectionner les centroïdes initiaux pour chacun des clusters.



Clustering : K-Means

- **Étape 1** : sélectionnez au hasard le premier centroïde parmi les points de données.
- **étape 2** : pour chaque point de données, calculez sa distance par rapport au centroïde le plus proche, choisi précédemment.
- **Etape 3**: Sélectionnez le prochain centroïde parmi les points de données de telle sorte que la probabilité de choisir un point comme centroïde soit directement proportionnelle à sa distance par rapport au centroïde le plus proche, choisi précédemment (c'est-à-dire que le point ayant la distance maximale par rapport au centroïde le plus proche est le plus susceptible d'être sélectionné ensuite comme centroïde).

Clustering : K-Means



Clustering : K-Means

- Supposons que la tâche d'exploration de données consiste à regrouper des points en trois groupes, où les points sont
- $A1(2,10)$, $A2(2,5)$, $A3(8,4)$, $B1(5,8)$, $B2(7,5)$, $B3(6,4)$, $c1(1,2)$, $c2(4,9)$.
- la fonction de distance est la distance euclidienne.
- Supposons qu'initialement nous attribuons $A1$, $B1$ et $C1$ comme centre de chaque groupe, respectivement.

Clustering : K-Means

Initial Centroids:

A1: (2, 10)

B1: (5, 8)

C1: (1, 2)

Data Points			Distance to						Cluster	New Cluster
			2	10	5	8	1	2		
A1	2	10								
A2	2	5								
A3	8	4								
B1	5	8								
B2	7	5								
B3	6	4								
C1	1	2								
C2	4	9								

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Clustering : K-Means

Initial Centroids:
A1: (2, 10)
B1: (5, 8)
C1: (1, 2)

Data Points			Distance to						Cluster	New Cluster
			x_2 2	y_2 10	5	8	1	2		
→ A1	2	10	0							
→ A2	2	5								
A3	8	4								
B1	5	8								
B2	7	5								
B3	6	4								
C1	1	2								
C2	4	9								

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2} = 0$$

:

Data Points			Distance to						Cluster	New Cluster
			2	10	5	8	1	2		
→ A1	2	10	0.00		3.61		8.06		1	
→ A2	2	5	5.00		4.24		3.16		3	
A3	8	4	8.49		5.00		7.28			
B1	5	8	3.61		0.00		7.21			
B2	7	5	7.07		3.61		6.71			
B3	6	4	7.21		4.12		5.39			
C1	1	2	8.06		7.21		0.00			
C2	4	9	2.24		1.41		7.62			

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Clustering : K-Means

Initial Centroids:

A1: (2, 10)

B1: (5, 8)

C1: (1, 2)

Data Points			Distance to						Cluster	New Cluster
			2	10	5	8	1	2		
A1	2	10	0.00		3.61		8.06		1	
A2	2	5	5.00		4.24		3.16		3	
A3	.8	4	8.49		5.00		7.28		2	-
B1	5	8	3.61		0.00		7.21		2	-
B2	7	5	7.07		3.61		6.71		2	-
B3	6	4	7.21		4.12		5.39		2	-
C1	1	2	8.06		7.21		0.00		3	
C2	4	9	2.24		1.41		7.62		2	-

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Clustering : K-Means

Initial Centroids:

A1: (2, 10)

B1: (5, 8)

C1: (1, 2)

New Centroids:

A1: (2, 10)

B1: (6, 6)

C1: (1.5, 3.5)

Data Points			Distance to						Cluster	New Cluster
			2	10	5	8	1	2		
A1	2	10	0.00		3.61		8.06		1	
A2	2	5	5.00		4.24		3.16		3	
A3	.8	4	8.49		5.00		7.28		2 -	
B1	5	8	3.61		0.00		7.21		2 -	
B2	7	5	7.07		3.61		6.71		2 -	
B3	6	4	7.21		4.12		5.39		2 -	
C1	1	2	8.06		7.21		0.00		3	
C2	4	9	2.24		1.41		7.62		2 -	

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Clustering : K-Means

Current Centroids:

A1: (2, 10)

B1: (6, 6)

C1: (1.5, 3.5)

New Centroids:

A1: (3, 9.5)

B1: (6.5, 5.25)

C1: (1.5, 3.5)

Data Points			Distance to						Cluster	New Cluster
			2	10	6	6	1.5	1.5		
A1	2	10	0.00		5.66		6.52		1	1
A2	2	5	5.00		4.12		1.58		3	3
A3	8	4	8.49		2.83		6.52		2	2
B1	5	8	3.61		2.24		5.70		2	2
B2	7	5	7.07		1.41		5.70		2	2
B3	6	4	7.21		2.00		4.53		2	2
C1	1	2	8.06		6.40		1.58		3	3
C2	4	9	2.24		3.61		6.04		2 → 1	1

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Clustering : K-Means

Current Centroids:

A1: (3, 9.5)

B1: (6.5, 5.25)

C1: (1.5, 3.5)

New Centroids:

A1: (3.67, 9) ✓

B1: (7, 4.33) ✓

C1: (1.5, 3.5) ✓

Data Points			Distance to						Cluster	New Cluster
			3	9.5	6.5	5.25	1.5	3.5		
A1	2	10	1.12		6.54		6.52		1	1
A2	2	5	4.61		4.51		1.58		3	3
A3	8	4	7.43		1.95		6.52		2	2
B1	5	8	2.50		3.13		5.70		2	1
B2	7	5	6.02		0.56		5.70		2	2
B3	6	4	6.26		1.35		4.53		2	2
C1	1	2	7.76		6.39		1.58		3	3
C2	4	9	1.12		4.51		6.04		1	1

$$d(p_1, p_2) = \sqrt{(x_2 - x_1)^2 + (y_2 - y_1)^2}$$

Clustering : DBSCAN

- DBSCAN (Density-Based Spatial Clustering of Applications with Noise) est une méthode basée sur la densité.
- Elle considère les clusters comme la région dense.
- Elle trouve des clusters de forme arbitraire en fonction de la densité des points de données dans différentes régions.

Clustering : DBSCAN

- Elle sépare les régions par zones de faible densité afin de pouvoir détecter les valeurs aberrantes entre les clusters à haute densité.
- Elle nécessite deux paramètres, ϵ qui définit le rayon de voisinage, c'est-à-dire que si la distance entre deux points est inférieure à ϵ , ils sont considérés comme voisins, minPts définit le nombre minimum de points dans le rayon ϵ .

L'apprentissage non-supervisé : clustering

Est une branche du machine learning qui vise à regrouper des données en fonction de leurs similitudes intrinsèques, sans qu'on ait préalablement défini de classes. Contrairement à la classification supervisée, on ne dispose pas d'étiquettes pour les données.

Théories sous-jacentes

Les théories qui sous-tendent le clustering sont nombreuses et variées, mais les plus fondamentales sont :

1. Théorie des ensembles et des relations

- **Similarité et distance:** Les algorithmes de clustering cherchent à minimiser la distance entre les éléments d'un même groupe et à maximiser la distance entre les groupes.
- **Partition:** Le clustering consiste à partitionner l'ensemble de données en sous-ensembles disjoints.

2. Théorie des graphes

- **Représentation des données:** Les données peuvent être représentées sous forme de graphe, où les nœuds sont les données et les arêtes représentent les relations entre elles.
- **Détection de communautés:** Le clustering peut être vu comme une tâche de détection de communautés dans un graphe.

3. Optimisation

- **Fonction objectif:** Les algorithmes de clustering cherchent à optimiser une fonction objectif, comme la somme des carrés des erreurs intra-cluster.
- **Algorithmes d'optimisation:** Des algorithmes comme les k-means utilisent des méthodes d'optimisation itératives pour trouver une partition optimale.

4. Géométrie

- **Espaces vectoriels:** Les données sont souvent représentées dans des espaces vectoriels de haute dimension.
- **Densité:** Certains algorithmes de clustering exploitent la notion de densité pour identifier les clusters.

Concepts clés en clustering

- **Cluster:** Un groupe d'objets similaires.
- **Centroid:** Un point central qui représente un cluster.
- **Similarité:** Mesure de la ressemblance entre deux objets.
- **Distance:** Mesure de la dissemblance entre deux objets.
- **Densité:** Nombre d'objets dans un voisinage donné.
- **Noyau:** Région dense d'objets.

Algorithmes de clustering populaires

- **K-means:** Partage les données en k groupes en minimisant la somme des carrés des distances intra-cluster.
- **Hierarchical clustering:** Crée une hiérarchie de clusters en fusionnant ou en divisant les clusters de manière itérative.
- **DBSCAN:** Identifie les clusters en fonction de la densité des données.

Algorithmes de clustering populaires

- **Spectral clustering:** Utilise les valeurs propres d'une matrice de similarité pour effectuer le clustering.
- **Gaussian mixture models (GMM):** Modélise les données comme un mélange de distributions gaussiennes.

Évaluation des modèles de clustering

L'évaluation des modèles de clustering est plus difficile que celle des modèles de classification car on ne dispose pas de vraies étiquettes. Les méthodes d'évaluation les plus courantes sont :

- **Indice de silhouette:** Mesure la qualité d'un clustering en évaluant à quel point un objet est bien classé dans son cluster par rapport aux autres clusters.

Évaluation des modèles de clustering

- **Indice de Calinski-Harabasz:** Mesure la séparation entre les clusters et la compacité au sein des clusters.
- **Visualisation:** Des techniques de visualisation comme les t-SNE ou UMAP peuvent aider à évaluer visuellement la qualité d'un clustering.

En résumé, le clustering est un outil puissant pour découvrir des structures cachées dans les données. Il est utilisé dans de nombreuses applications, telles que la segmentation de marché, la détection d'anomalies, et la compression de données.

{ Séance 5()

‘Ingénierie des fonctionnalités :’

}

Qu'est-ce que l'ingénierie des fonctionnalités ?

- L'ingénierie des fonctionnalités, en science des données, fait référence à la manipulation (ajout, suppression, combinaison, mutation) de votre ensemble de données pour améliorer la formation du modèle d'apprentissage automatique, ce qui conduit à de meilleures performances et à une plus grande précision.
- Une ingénierie des fonctionnalités efficace repose sur une bonne connaissance du problème et des sources de données disponibles.

Les étapes clés de l'ingénierie des fonctionnalités

L'ingénierie des fonctionnalités consiste à transformer les données brutes en un format qui améliore les performances des modèles d'apprentissage automatique.

- **Exploration et compréhension des données** : explorez et comprenez l'ensemble de données, y compris les types de fonctionnalités et leurs distributions. Il est essentiel de comprendre la forme des données.

- **Gestion des données manquantes** : traitez les valeurs manquantes par imputation ou suppression d'instances ou de fonctionnalités avec des données manquantes. Il existe de nombreuses approches algorithmiques pour gérer les données manquantes.
- **Encodage des variables** : convertissez les variables catégorielles en un format numérique adapté aux algorithmes d'apprentissage automatique à l'aide de méthodes.
- **Mise à l'échelle des fonctionnalités** : normalisez ou normalisez les fonctionnalités numériques pour vous assurer qu'elles sont à une échelle similaire, améliorant ainsi les performances du modèle.

- **Création de fonctionnalités** : générez de nouvelles fonctionnalités en combinant celles existantes pour capturer les relations entre les variables.
- **Gestion des valeurs aberrantes** : identifiez et traitez les valeurs aberrantes dans les données grâce à des techniques telles que le découpage ou la transformation des données.
- **Normalisation** : normalisez les fonctionnalités pour les amener à une échelle commune, ce qui est important pour les algorithmes sensibles aux magnitudes des fonctionnalités.

- **Binning ou Discrétisation** : Convertissez les caractéristiques continues en compartiments discrets pour capturer des modèles spécifiques dans certaines plages.
- **Traitement des données textuelles** : Si vous traitez des données textuelles, effectuez des tâches telles que la tokenisation, la dérivation et la suppression des mots vides.
- **Caractéristiques de séries chronologiques** : Extrayez les caractéristiques temporelles pertinentes telles que les caractéristiques de décalage ou les statistiques de roulement pour les données de séries chronologiques.

- **Caractéristiques vectorielles** : Les caractéristiques vectorielles sont couramment utilisées pour la formation en apprentissage automatique. Dans l'apprentissage automatique, les données sont représentées sous forme de caractéristiques, et ces caractéristiques sont souvent organisées en vecteurs. Un vecteur est un objet mathématique qui a à la fois une amplitude et une direction et peut être représenté sous la forme d'un tableau de nombres.
- **Sélection de caractéristiques** : Identifiez et sélectionnez les caractéristiques les plus pertinentes pour améliorer l'interprétabilité et l'efficacité du modèle à l'aide de techniques telles que la sélection de caractéristiques univariées ou l'élimination de caractéristiques récurives.

- **Transformation(Extraction) de caractéristiques** : L'extraction de caractéristiques vise à réduire la complexité des données (souvent appelée « dimensionnalité des données ») tout en conservant autant d'informations pertinentes que possible. Cela permet d'améliorer les performances et l'efficacité des algorithmes d'apprentissage automatique et de simplifier le processus d'analyse. L'extraction de caractéristiques peut impliquer la création de nouvelles caractéristiques (« ingénierie des caractéristiques ») et la manipulation des données pour séparer et simplifier l'utilisation des caractéristiques significatives de celles qui ne le sont pas. Créez de nouvelles caractéristiques ou réduisez la dimensionnalité à l'aide de techniques telles que l'analyse en composantes principales (PCA) ou l'intégration de voisins stochastiques distribués en t (t-DSNE).

- **Validation croisée** : la sélection de caractéristiques avant la validation croisée peut introduire un biais important. Évaluez l'impact de l'ingénierie des caractéristiques sur les performances du modèle à l'aide de techniques de validation croisée.

L'ingénierie des caractéristiques est souvent un processus itératif ; évaluez, affinez et répétez selon les besoins pour obtenir des résultats optimaux. Ces étapes peuvent varier en fonction de la nature des données et de la tâche d'apprentissage automatique, mais collectivement, elles contribuent à créer un ensemble de caractéristiques robuste et efficace pour la formation du modèle.


Feature Selection

Sélection de caractéristiques : Identifiez et sélectionnez les caractéristiques les plus pertinentes pour améliorer l'interprétabilité et l'efficacité du modèle à l'aide de techniques telles que la sélection de caractéristiques univariées ou l'élimination de caractéristiques récursives.

Feature Extraction : Feature Transformation

Identifiez et sélectionnez les caractéristiques les plus pertinentes pour améliorer l'interprétabilité et l'efficacité du modèle à l'aide de techniques telles que la sélection de caractéristiques univariées ou l'élimination de caractéristiques récurives.

Feature Engineering Pipeline



Analyse des composantes principales

Identifiez et sélectionnez les caractéristiques les plus pertinentes pour améliorer l'interprétabilité et l'efficacité du modèle à l'aide de techniques telles que la sélection de caractéristiques univariées ou l'élimination de caractéristiques récurives.

Analyse des composantes principales (Etape par Etape)

1. L'analyse en composantes principales (ACP) est une technique de réduction de dimensionnalité linéaire avec des applications dans la visualisation d'analyses de données exploratoires et le prétraitement des données.
 - Étant donné les données du tableau, réduisez la dimension de 2 à 1 en utilisant l'algorithme d'analyse en composantes principales (ACP).

Analyse des composantes principales (Etape par Etape)

Étape 1 : Calculer la matrice de covariance

$$cov(x, x) = \frac{\sum (x - \bar{x}) (x - \bar{x})}{n - 1}$$

$$cov(x, y) = \frac{\sum (x - \bar{x}) (y - \bar{y})}{n - 1}$$

$$cov(y, x) = \frac{\sum (y - \bar{y}) (x - \bar{x})}{n - 1}$$

$$cov(y, y) = \frac{\sum (y - \bar{y}) (y - \bar{y})}{n - 1}$$

$$\bullet C = \begin{bmatrix} Cov(x, x) & Cov(x, y) \\ Cov(y, x) & Cov(y, y) \end{bmatrix}$$

X	Y
2.5	2.4
0.5	0.7
2.2	2.9
1.9	2.2
3.1	3.0
2.3	2.7
2	1.6
1	1.1
1.5	1.6
1.1	0.9

Analyse des composantes principales (Etape par Etape)

Étape 1 : Calculer la matrice de covariance

	X	Y	$(X - \bar{X})$	$(Y - \bar{Y})$	$(X - \bar{X})^2$	$(Y - \bar{Y})^2$	$(X - \bar{X}) * (Y - \bar{Y})$
	2.5	2.4	0.69	0.49	0.4761	0.2401	0.3381
	0.5	0.7	-1.31	-1.21	1.7161	1.4641	1.5851
	2.2	2.9	0.39	0.99	0.1521	0.9801	0.3861
	1.9	2.2	0.09	0.29	0.0081	0.0841	0.0261
	3.1	3.0	1.29	1.09	1.6641	1.1881	1.4061
	2.3	2.7	0.49	0.79	0.2401	0.6241	0.3871
	2	1.6	0.19	-0.31	0.0361	0.0961	-0.0589
	1	1.1	-0.81	-0.81	0.6561	0.6561	0.6561
	1.5	1.6	-0.31	-0.31	0.0961	0.0961	0.0961
	1.1	0.9	-0.71	-1.01	0.5041	1.0201	0.7171
Sum	18.1	19.1			5.549	6.449	5.539
Mean	1.81	1.91		Sum/(n-1)	0.6166	0.7166	0.6154

X	Y
2.5	2.4
0.5	0.7
2.2	2.9
1.9	2.2
3.1	3.0
2.3	2.7
2	1.6
1	1.1
1.5	1.6
1.1	0.9

Analyse des composantes principales (Etape par Etape)

Étape 1 : Calculer la matrice de covariance

$$C = \begin{bmatrix} 0.6166 & 0.6154 \\ 0.6154 & 0.7166 \end{bmatrix}$$

Étape 2 : Valeurs propres du calculateur

$$|C - \lambda I| = 0$$

C = Matrice de Covariance

lamda = la matrice diagonale des valeurs propres.

Étape 2 : la matrice diagonale des valeurs propres.

$$\begin{vmatrix} 0.6166 & 0.6154 \\ 0.6154 & 0.7166 \end{vmatrix} - \lambda \begin{vmatrix} 1 & 0 \\ 0 & 1 \end{vmatrix} = 0$$

$$\begin{vmatrix} 0.6166 - \lambda & 0.6154 \\ 0.6154 & 0.7166 - \lambda \end{vmatrix} = 0$$

Étape 2 : la matrice diagonale des valeurs propres.

$$(0.6166 - \lambda) * (0.7166 - \lambda) - 0.6154^2 = 0$$

$$\lambda^2 - 1.333\lambda + 0.0630 = 0$$

$$\lambda_1 = 0.049$$

$$\lambda_2 = 1.284$$

Étape 3 : Calculer les Vecteurs propres

$$Cv_1 = \lambda v_1 \quad \left| \begin{array}{cc} 0.6166 & 0.6154 \\ 0.6154 & 0.7166 \end{array} \right| * \begin{bmatrix} x_1 \\ y_1 \end{bmatrix} = 0,049 * \begin{bmatrix} x_1 \\ y_1 \end{bmatrix}$$

$$\begin{cases} 0.6166x_1 + 0.6154y_1 = 0.0490x_1 & (1) \\ 0.6154x_1 + 0.7166y_1 = 0.0490y_1 & (2) \end{cases}$$

Étape 3 : Calculer les Vecteurs propres

$$\begin{cases} 0.5676x_1 = -0.6154y_1 & (1) \\ 0.6154x_1 = -0.6676y_1 & (2) \end{cases}$$

$$v_1 = \begin{bmatrix} \frac{-1.084}{\sqrt{1.084^2 + 1^2}} \\ \frac{1}{\sqrt{1.084^2 + 1^2}} \end{bmatrix}$$

$$v_1 = \begin{bmatrix} -1.084 \\ 1 \end{bmatrix}$$

$$v_1 = \begin{bmatrix} -0.735 \\ 0.678 \end{bmatrix}$$

Étape 3 : Calculer les Vecteurs propres

$$Cv_2 = \lambda v_2$$

$$\begin{cases} 0.6674x_1 = -0.6154y_1 & (7) \\ 0.6154x_1 = -0.5674y_1 & (8) \end{cases}$$

$$\begin{vmatrix} 0.6166 & 0.6154 \\ 0.6154 & 0.7166 \end{vmatrix} * \begin{bmatrix} x_2 \\ y_2 \end{bmatrix} = 1.284 * \begin{bmatrix} x_2 \\ y_2 \end{bmatrix}$$

$$\begin{cases} 0.6166x_2 + 0.6154y_2 = 1.284x_2 & (5) \end{cases}$$

$$\begin{cases} 0.6154x_2 + 0.7166y_2 = 1.284y_2 & (6) \end{cases}$$

$$v_2 = \begin{bmatrix} 0.922 \\ 1 \end{bmatrix}$$

Étape 3 : Calculer les Vecteurs propres

$$v_1 = \begin{bmatrix} \frac{0.922}{\sqrt{0.922^2 + 1^2}} \\ \frac{1}{\sqrt{0.922^2 + 1^2}} \end{bmatrix}$$

$$v_2 = \begin{bmatrix} 0.677 \\ 0.735 \end{bmatrix}$$

Étape 4 : reformuler les données selon les axes des composantes principales.

$$New = F * v_2 \quad v_1 = \begin{bmatrix} -0.735 \\ 0.678 \end{bmatrix}$$


$$\lambda_1 = 0.049 \quad v_2 = \begin{bmatrix} 0.677 \\ 0.735 \end{bmatrix}$$

$$\lambda_2 = 1.284$$

Étape 4 : reformuler les données selon les axes des composantes principales.

$$New = \begin{bmatrix} 2.5 & 2.4 \\ 0.5 & 0.7 \\ 2.2 & 2.9 \\ 1.9 & 2.2 \\ 3.1 & 3 \\ 2.3 & 2.7 \\ 2 & 1.6 \\ 1 & 1.1 \\ 1.5 & 1.6 \\ 1.1 & 0.9 \end{bmatrix} * \begin{bmatrix} 0.677 \\ 0.735 \end{bmatrix} = \begin{bmatrix} 3.4565 \\ 0.853 \\ 3.6209 \\ 2.9033 \\ 4.3037 \\ 3.5416 \\ 2.53 \\ 1.4855 \\ 2.1915 \\ 1.4062 \end{bmatrix}$$


Étape 4 : reformuler les données selon les axes des composantes principales.



X	Y
2.5	2.4
0.5	0.7
2.2	2.9
1.9	2.2
3.1	3.0
2.3	2.7
2	1.6
1	1.1
1.5	1.6
1.1	0.9

Étape 4 : reformuler les données selon les axes des composantes principales.

$$New = \begin{bmatrix} 3.4565 \\ 0.853 \\ 3.6209 \\ 2.9033 \\ 4.3037 \\ 3.5416 \\ 2.53 \\ 1.4855 \\ 2.1915 \\ 1.4062 \end{bmatrix}$$



$$\begin{aligned} \bar{x} &= 1.91 \\ \bar{y} &= 1.81 \\ v_1 &= \begin{bmatrix} -0.735 \\ 0.678 \end{bmatrix} \\ v_2 &= \begin{bmatrix} 0.677 \\ 0.735 \end{bmatrix} \end{aligned}$$